TECHNISCHE UNIVERSITÄT BERLIN

ISDA Informationssysteme und Datenanalyse
02 Datenbankmodellierung II

Dr. Alexander Borusan | FG DIMA

Was sollten wir bereits wissen

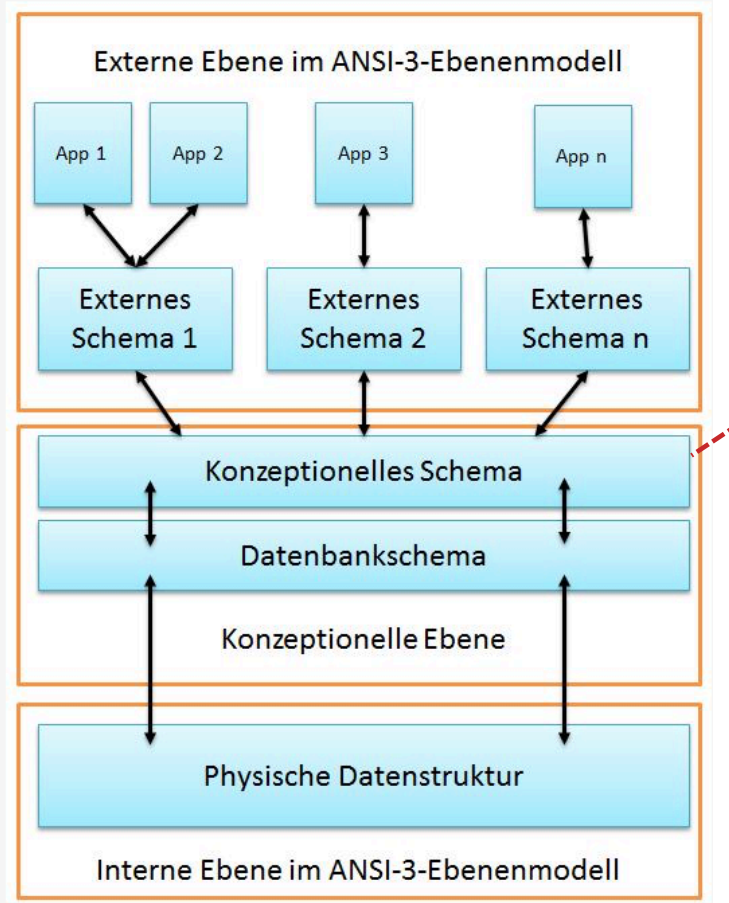

- Abgrenzung der Miniwelt infolge der Anforderungsanalyse.
- Erstellung eines konzeptionellen Schemas (Architektur) für die Datenbank in Form eines syntaktisch-korrekten ER-Diagramm, das unabhängig von einem bestimmten DBMS ist.
- Beschreibungsmittel: ER - Diagramme mit Grundkonzepten *Entity-Typ, Relationship-Typ, Attribut, Integritätsbedingung IB: Kardinalität und Totalität.*
- Modellierung von Nebenbedingungen*: rekursiver Entity.Typ, schwacher Entity-Typ, Schlüssel, referentielle Integrität.*
- Methodik für komplexe ER-Diagramme: von der Definition der Miniwelt zu einem anwendungsorientierten konzeptionellen Schema.
- Semantik der Grundkonzepte der ER-Diagramme.

Was werden wir heute lernen

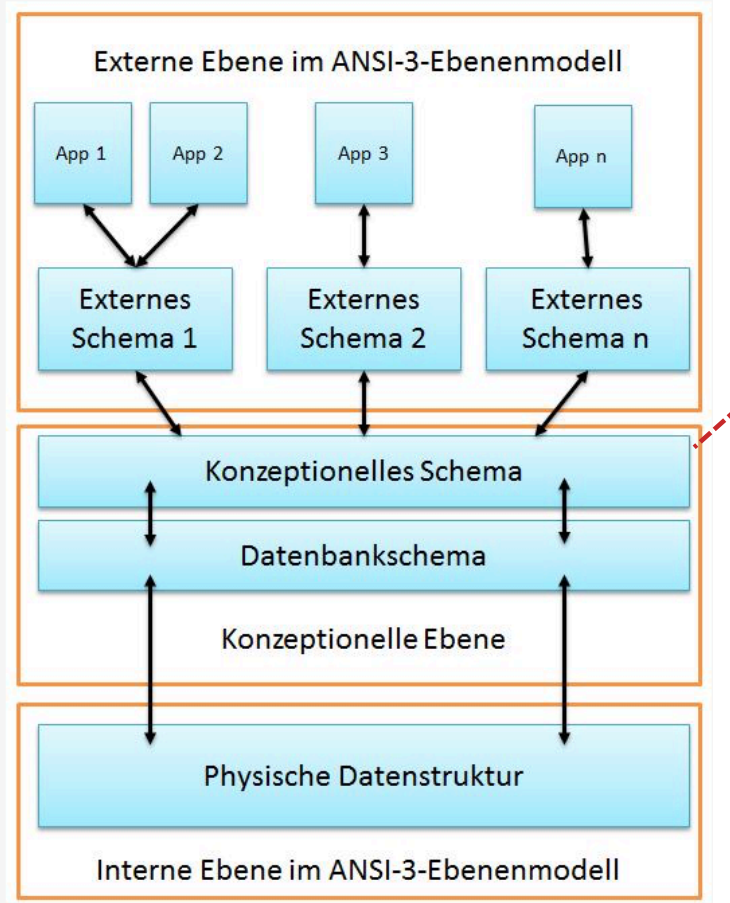

- Abstraktionskonzepte für die Erstellung eines konzeptionellen Schemas (Architektur) für die Datenbank als erweitertes ER-Diagramm (EER-Diagramm).
- Modellierung der Generalisierung/Spezialisierung: Notation, Integritätsbedingungen: partiell, total, disjunkt, überlappend.
- Modellierung der Aggregation: Notation und Integritätsbedingungen.
- Methodik für den konzeptionellen Datenbankentwurf: Drei Phasen, Sichtenintegration, Integrationskonflikte.

Überblick

- Erweiterte ER-Diagramme (EER-Diagramme)
- Designprinzipien
- Methodik für das konzeptionelles Schema
- Sichtenintegration
- Zusammenfassung und Ausblick

Erweiterungen für die ER-Diagramme

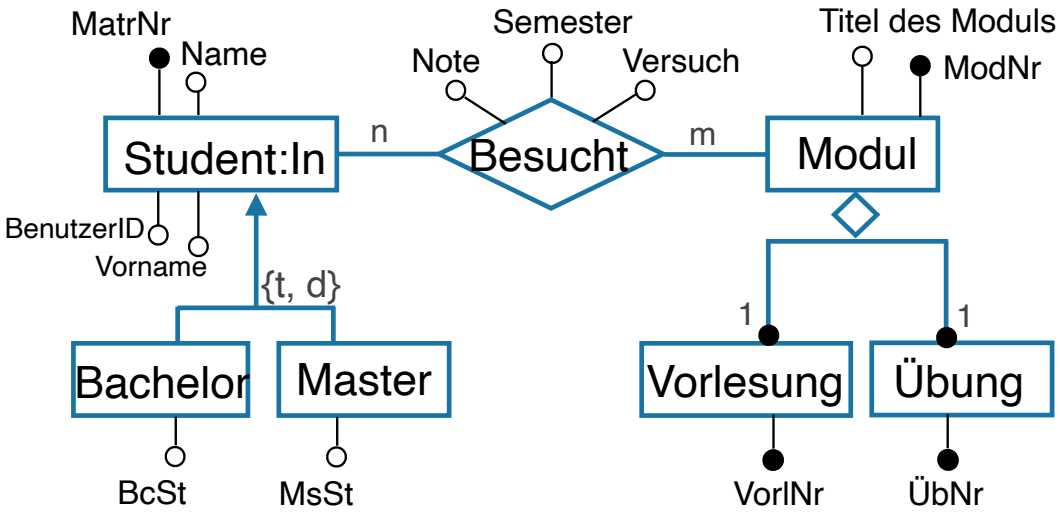

- Generalisierung / Spezialisierung
- Das Abstraktionskonzept der Generalisierung ermöglicht es, eine Menge "speziellerer„ (oder: "zu generalisierender") Entity-Typen zu einem "allgemeineren" (oder: "generalisierten") Entity-Typ zu abstrahieren aufgrund gemeinsamer Eigenschaften (Attribute), z.B. Bachelor und Master zu Student:In. Die korrespondierende vertikale Beziehung hier “Ist-Ein-Von”.

- Aggregation
- Die Aggregationsabstraktion ermöglicht, ‘komplexe Strukturen‘ in ihrem Aufbau aus Einzelkomponenten (Teilen) zu beschreiben. Die korrespondierende vertikale Beziehung wird demzufolge als „Ist-Teil-von“ - Relationship-Typ bezeichnet, z.B. Vorlesung und Übung sind Teile eines Moduls.

Generalisierung und Spezialisierung: Definition und Notation

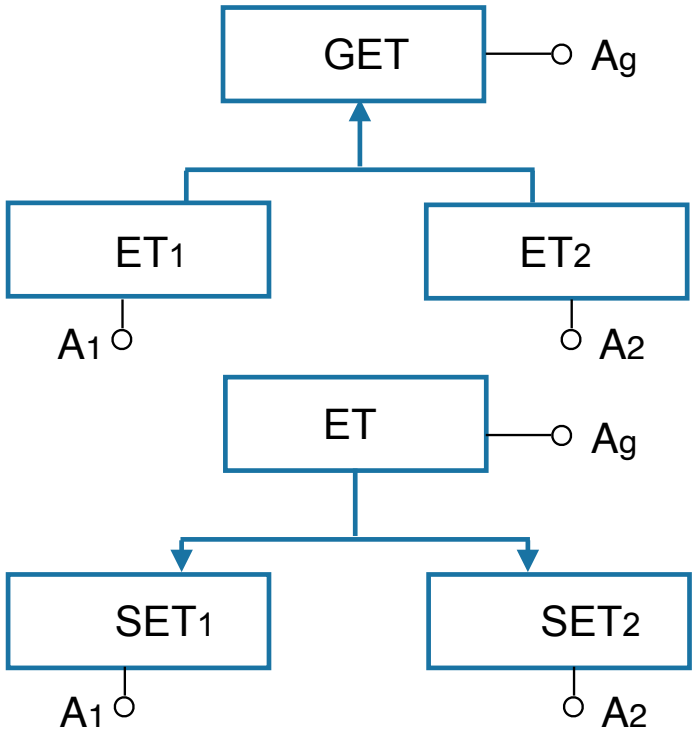

- Generalisierung ist der Prozess, bei dem die Unterschiede A_1 und A_2 zwischen mehreren Entity-Typen unterdrückt werden und sie zu einer einzigen Superklasse GET mit gemeinsamen Eigenschaften Ag generalisiert werden, in der die ursprünglichen Entity-Typen ET_1 und ET_2 spezielle Subklassen sind.

- Spezialisierung ist der Prozess der Definition einer *Menge von Subklassen* eines Entity-Typs ET. Dieser Entity-Typ wird als Superklasse der Spezialisierungen SET_1 und SET_2 bezeichnet.

Integritätsbedingungen der Generalisierung / Spezialisierung

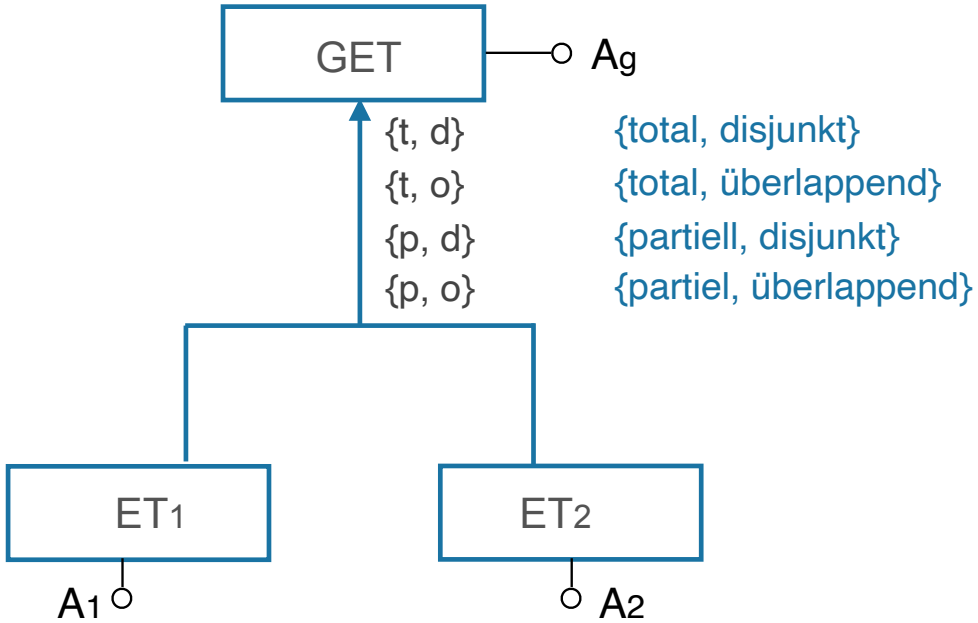

- Volständigkeit-Einschränkung: Eine totale Generalisierung bestimmt, dass jede Entität der Subklasse Mitglied in einer Superklasse der Generalisierung sein muss. Bei der partiellen Generalisierung muss eine Entität der Generalisierung nicht unbedingt zu einer Subklassen gehören.

- Disjunkheit-Einschränkung: Es wird sichergestellt, dass die Subklassen der Generalisierung disjunkt sein müssen. Wenn die Subklassen nicht auf disjunkt eingeschränkt sind, können ihre Entitätsmengen überlappen, was mit **o** dargestellt wird.

Integritätsbedingungen der Generalisierung: Beispiele

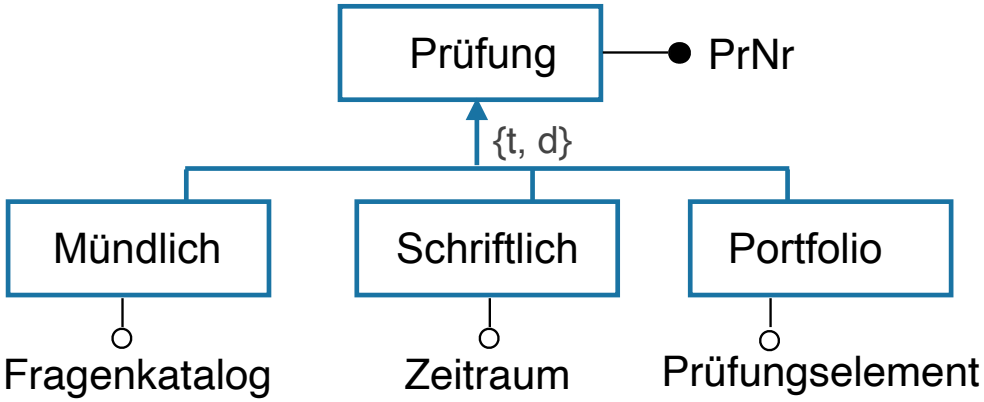

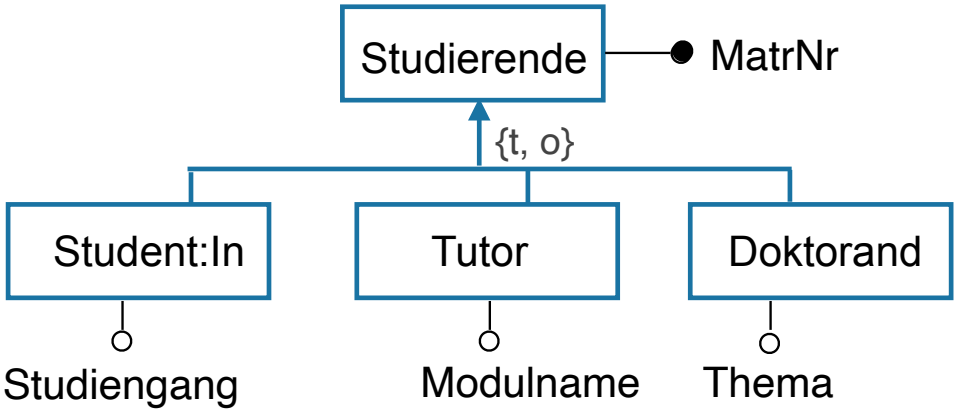

- {total, disjunkt}:
  Jede (total) Prüfung an der TU Berlin ist laut der AllgStuPO vom 6. August 2015 ist entweder *mündliche Prüfung*, *schriftliche Prüfung* oder *Portfolioprüfung* (disjunkt).

- {total, überlappend}:
  Jede (total) Studierende an der TU Berlin ist als Student:In immatrikuliert. Die besonders erfolgreichen Student:innen können als Tutor:inen beschäftigt werden (überlappend).

Integritätsbedingungen der Generalisierung: Beispiele

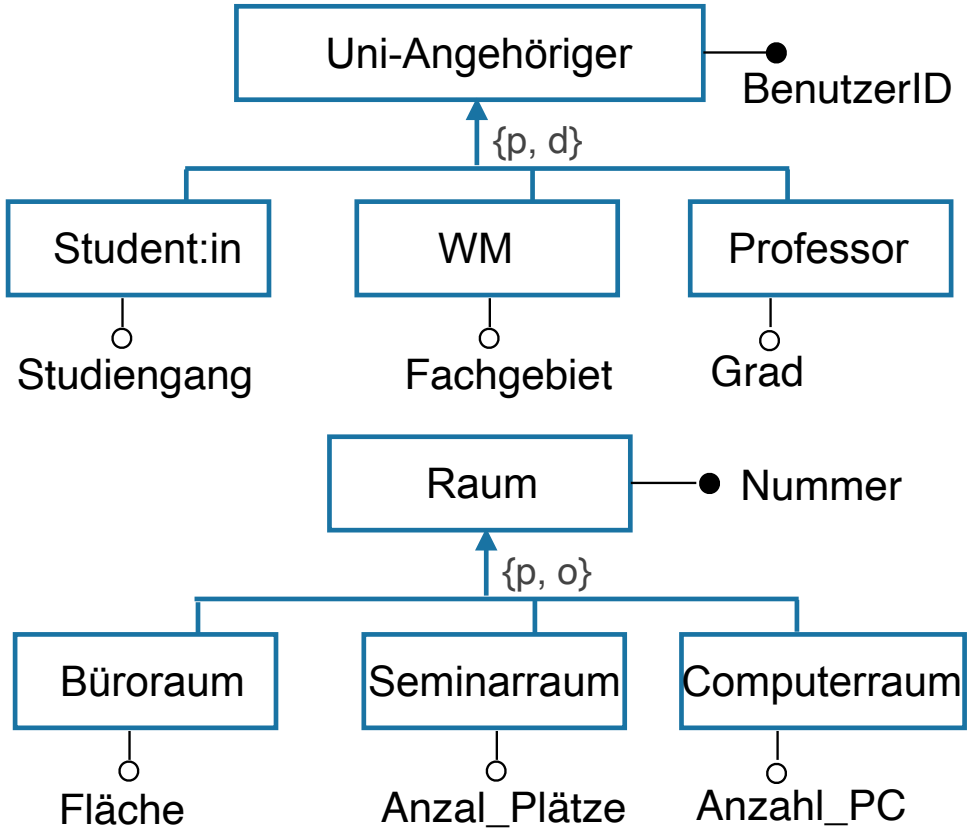

- {partiell disjunkt}:
  Die Statusgruppen sind (per Gesetz) disjunkt (ausschließend). Es gibt weitere Spezialisierungen von Universitätsangehöriger, die im Modell nicht erfasst sind, z.B. sonstige Dienstkräfte, etc. (partiell). Sie sind aber in der Generalisierung Uni-Angehöriger enthalten.

- {partiell, überlappend}:
  Die Computerräume können als Seminarräume benutzt werden (überlappend). Es gibt auch weitere Räume , die im Modell nicht erfasst sind, z.B. Teeküchen, Sekretariate, etc. (partiell), die alle aber in der Generalisierung Raum enthalten sind.

Komplexes EER-Diagramm

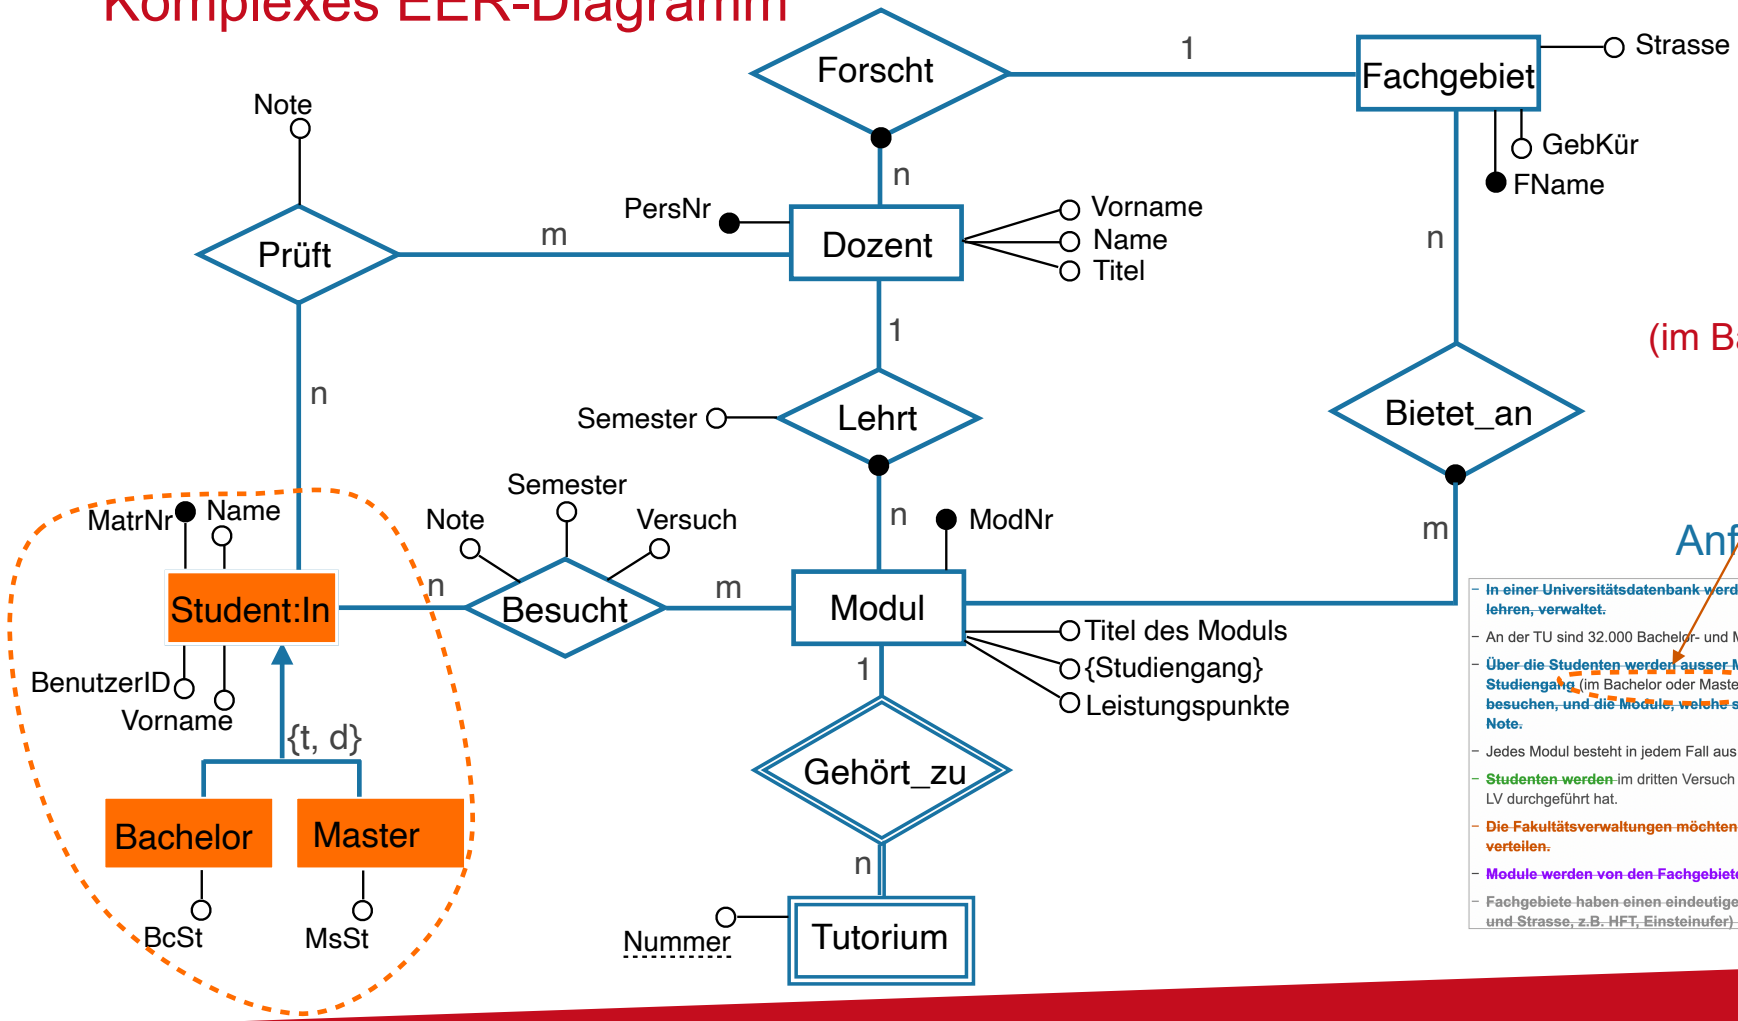

(im Bachelor und Master)

Anforderungsanalyse

- ~~In einer Universitätsdatenbank werden Daten über Studenten, Module und Dozenten, welche die Module lehren, verwaltet.~~
- An der TU sind 32.000 Bachelor- und Master-Studenten immatrikuliert.
- ~~Über die Studenten werden ausser Matrikelnummer, Vornamen, Namen und Kontonamen zusätzlich der Studiengang~~ (im Bachelor oder Master) sowie ~~die Lehrveranstaltungen verwaltet, welche sie aktuell besuchen, und die Module, welche sie bereits besucht haben, mit dem Semester, dem Versuch und der Note.~~
- Jedes Modul besteht in jedem Fall aus genau einer Vorlesung und genau einer Übung.
- ~~Studenten werden~~ im dritten Versuch mündlich nur ~~von dem Lehrveranstalter geprüft,~~ der die nichtbestandene LV durchgeführt hat.
- ~~Die Fakultätsverwaltungen möchten die DB benutzen, um den Tutor:Innen-Pool auf die Tutorien zu verteilen.~~
- ~~Module werden von den Fachgebieten angeboten~~, ~~an welchen die Dozenten forschen~~.
- ~~Fachgebiete haben einen eindeutigen Namen und werden in Gebäuden der Universität (mit Gebäudekürzel und Strasse, z.B. HFT, Einsteinufer) untergebracht.~~

Generalisierung => ERD

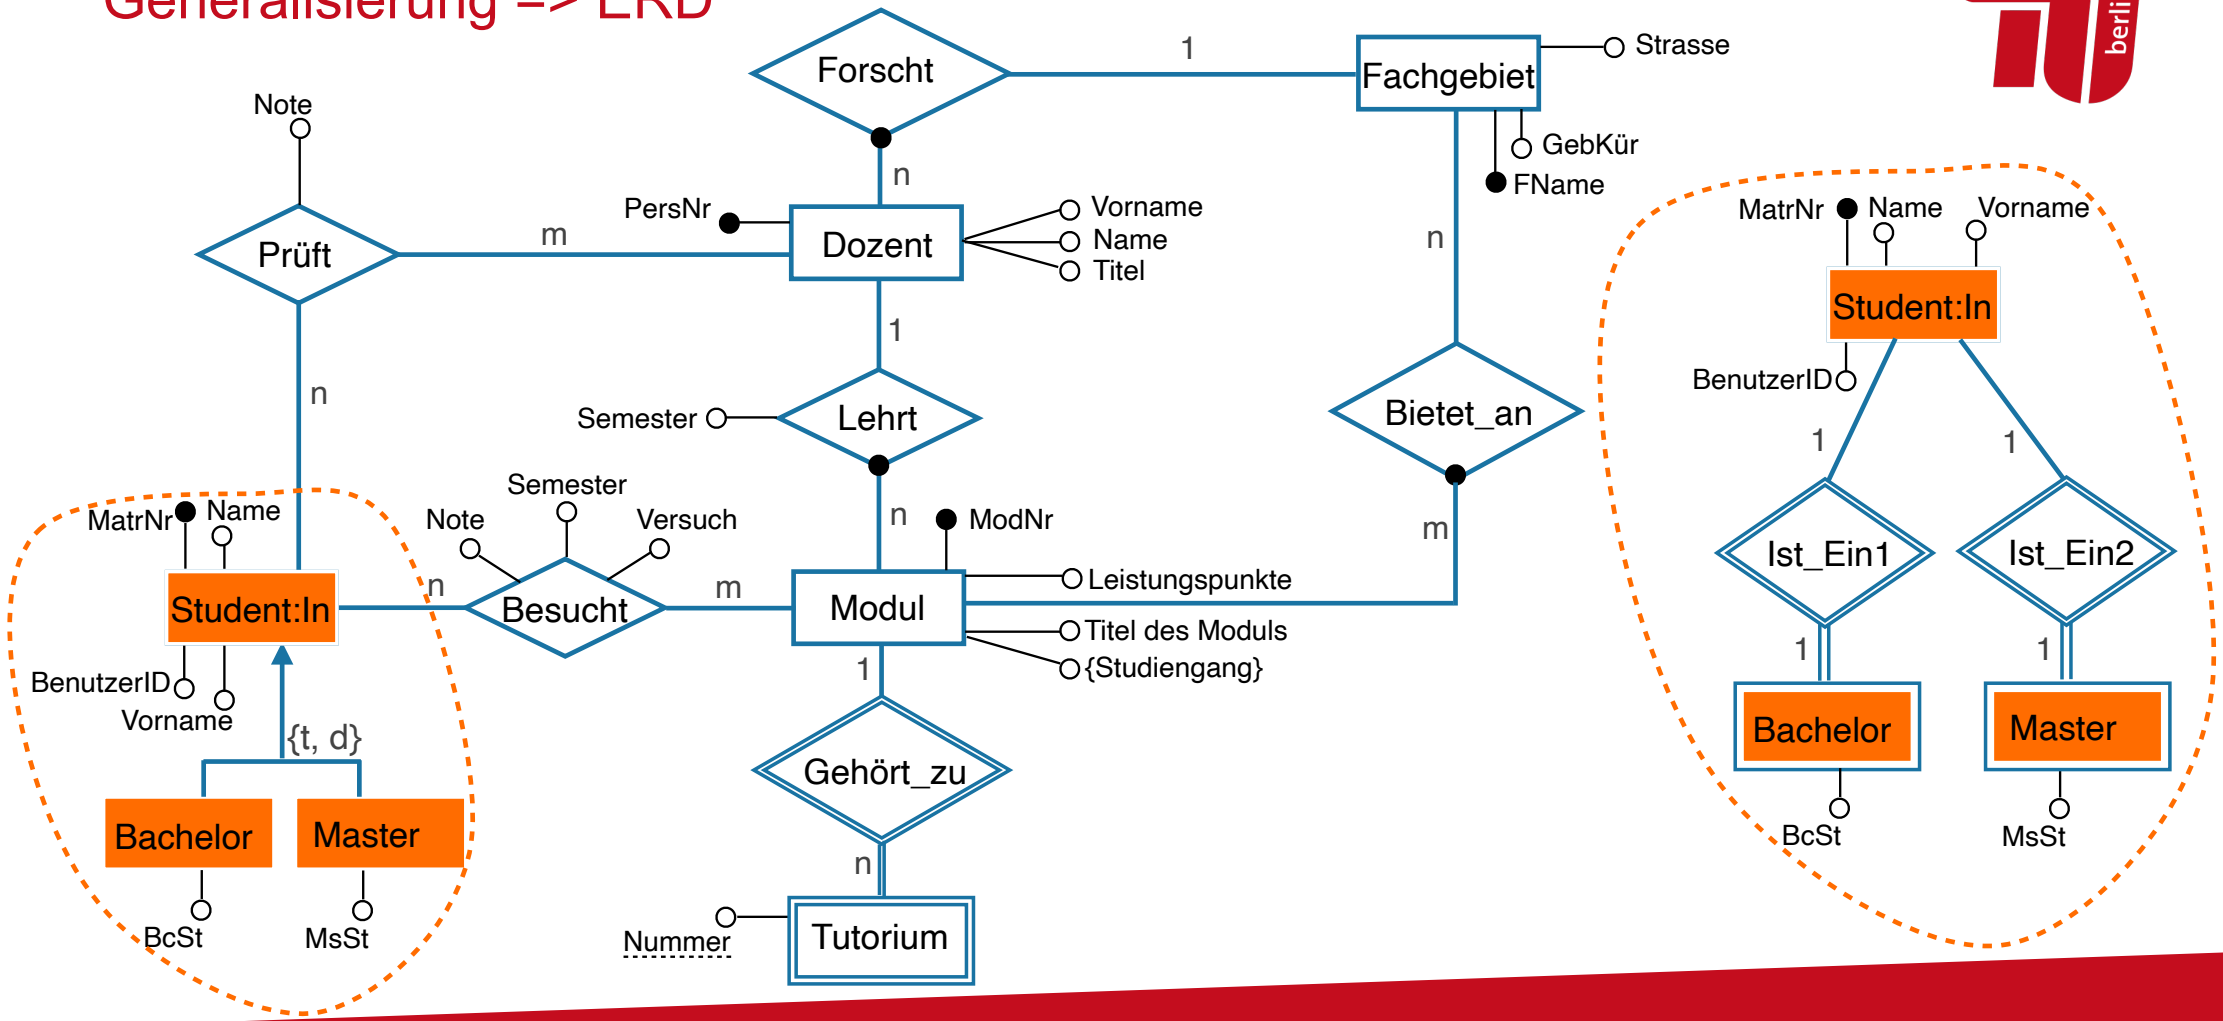

Aggregation: Definition und Notation

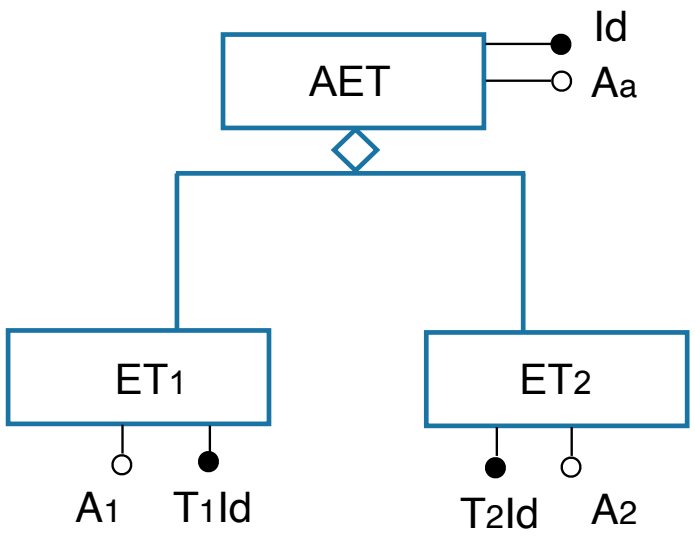

- Aggregation ist ein Abstraktionskonzept für den Aufbau zusammengesetzter Objekte aus seinen Komponentenobjekten. Die vertikale Aggregationsbeziehung (Notation kleine Raute) wird als eine gewöhnliche Beziehung dargestellt.

- Aggregation ist der Prozess, bei dem das Entität des aggregierten Entity-Typs AET aus den unterschiedlichen anderen Entitäten der anderen Entity-Typen ET_1, ET_2, etc. zusammengesetzt.

Integritätsbedingungen der Aggregation

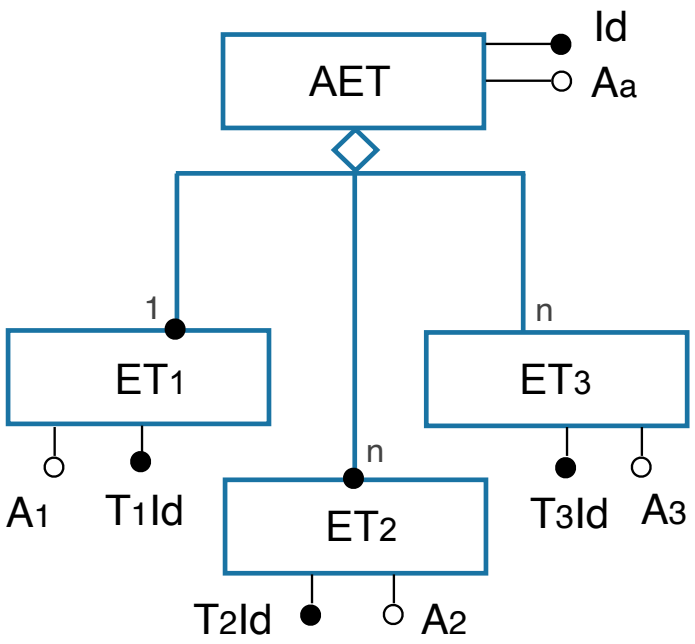

- Kardinalität: Äquivalent zu ER-Diagrammen muss die Kardinalität der Beziehung auch bei Aggregationsbeziehungen angegeben werden (als 1 oder n). Hinter jeder Aggregationsbeziehung steht dabei eine Spezifikation, welche als mathematische Integritätsbedingung formal ausgedrückt werden kann (*siehe Folie 34, Foliensatz zu KW17, dort Nr. 6.*). Hierbei würde der abstrakte Wert "1" oder "n" eine konkrete Ausprägung annehmen.

- Totalität (schwarzer Punkt am ET_1 und ET_2): Jede Entität des Aggregats AET muss in Verbindung zu mindestens einem Entity-Typen der Komponenten ET1 bzw. ET2 stehen. Diese Verbindung ist zu Entities von ET3 optional. Die Obergrenze wir durch die Angabe einer Kardinalität bzw. einer weiteren Integritätsbedingung angegeben.

Integritätsbedingungen der Aggregation: Beispiele

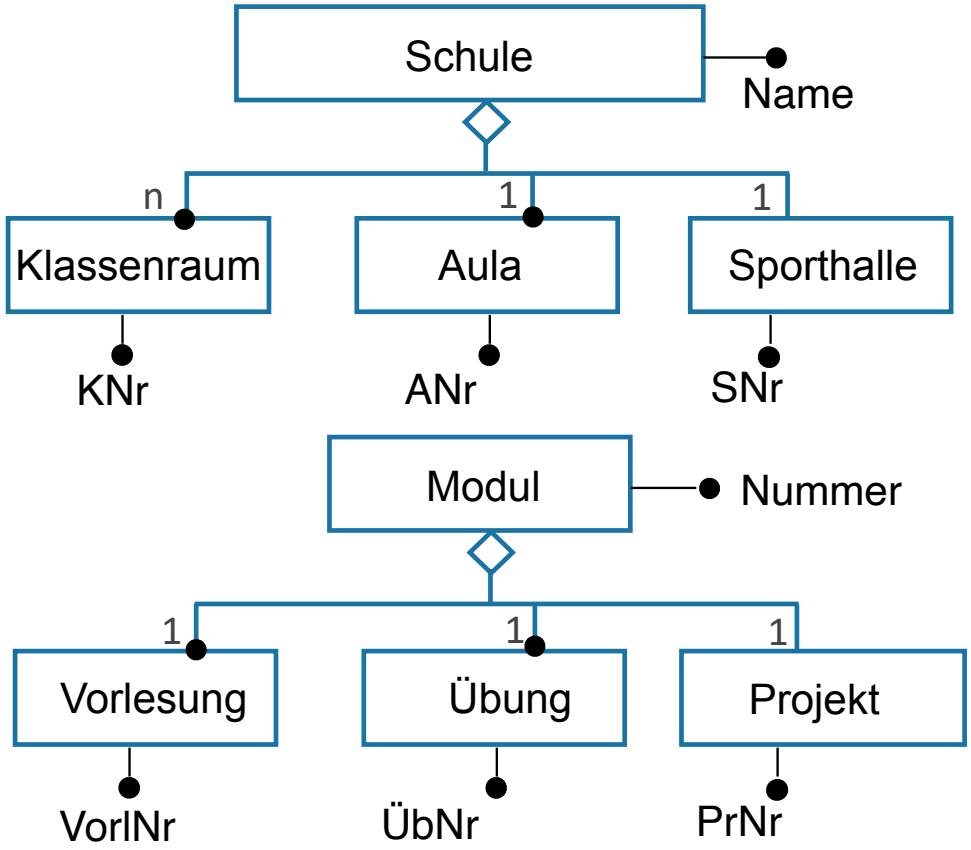

- Eine Schule besteht aus mehreren (n) Klassenräumen (genaue Angabe). Dagegen wollen wir nicht mehr als eine Aula und eine Turnhalle erlauben. Zusätzlich könnte man hier über die Totalität noch die Existenz bestimmter Komponenten erzwingen, etwa der Klassenräume und der Aula!)

- Ein Modul besteht aus einer Vorlesung und einer Übung. Die Totalität hinweist , dass jede Ausprägung des Moduls in jedem Fall aus der Vorlesung und Übung besteht und möglicherweise aus dem optionalen Projekt.

Komplexes EER-Diagramm

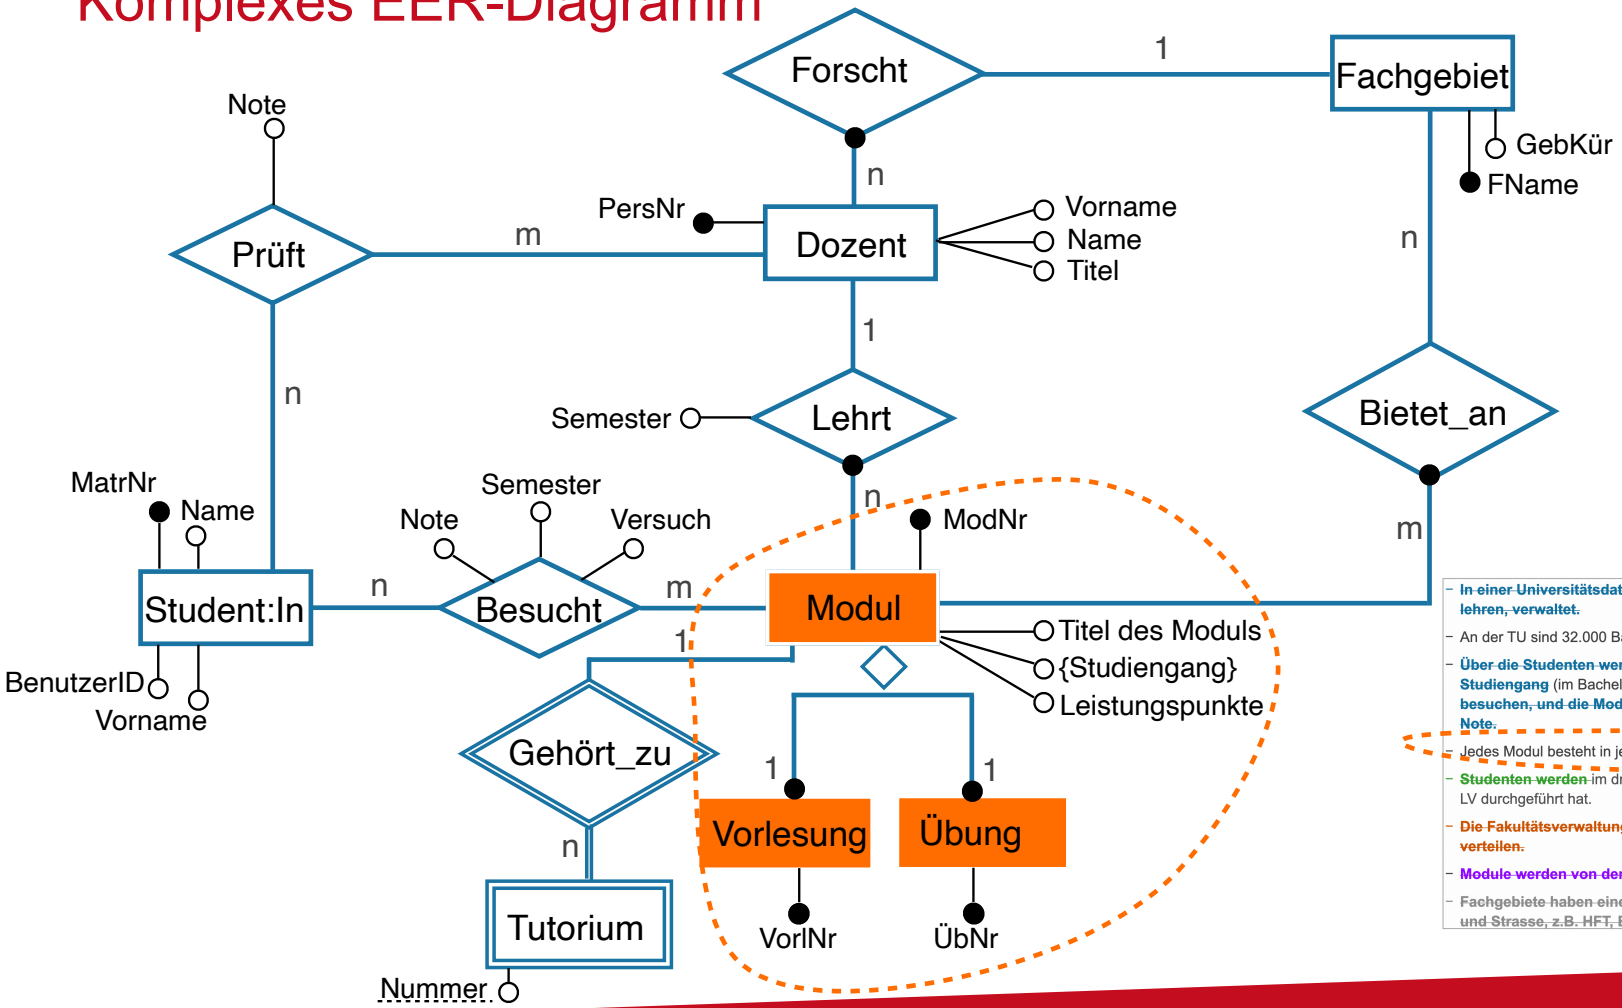

(Jedes Modul besteht in jedem Fall aus genau einer Vorlesung und genau einer Übung)

Anforderungsanalyse

- ~~In einer Universitätsdatenbank werden Daten über Studenten, Module und Dozenten, welche die Module lehren, verwaltet.~~
- An der TU sind 32.000 Bachelor- und Master-Studenten immatrikuliert.
- ~~Über die Studenten werden ausser Matrikelnummer, Vornamen, Namen und Kontonamen zusätzlich der Studiengang~~ (im Bachelor oder Master) sowie ~~die Lehrveranstaltungen verwaltet, welche sie aktuell besuchen, und die Module, welche sie bereits besucht haben, mit dem Semester, dem Versuch und der Note.~~
- Jedes Modul besteht in jedem Fall aus genau einer Vorlesung und genau einer Übung.
- ~~Studenten werden~~ im dritten Versuch mündlich nur ~~von dem Lehrveranstalter geprüft,~~ der die nichtbestandene LV durchgeführt hat.
- ~~Die Fakultätsverwaltungen möchten die DB benutzen, um den Tutor:Innen-Pool auf die Tutorien zu verteilen.~~
- ~~Module werden von den Fachgebieten angeboten, an welchen die Dozenten forschen.~~
- ~~Fachgebiete haben einen eindeutigen Namen und werden in Gebäuden der Universität (mit Gebäudekürzel und Strasse, z.B. HFT, Einsteinufer) untergebracht.~~

Aggregation => ERD

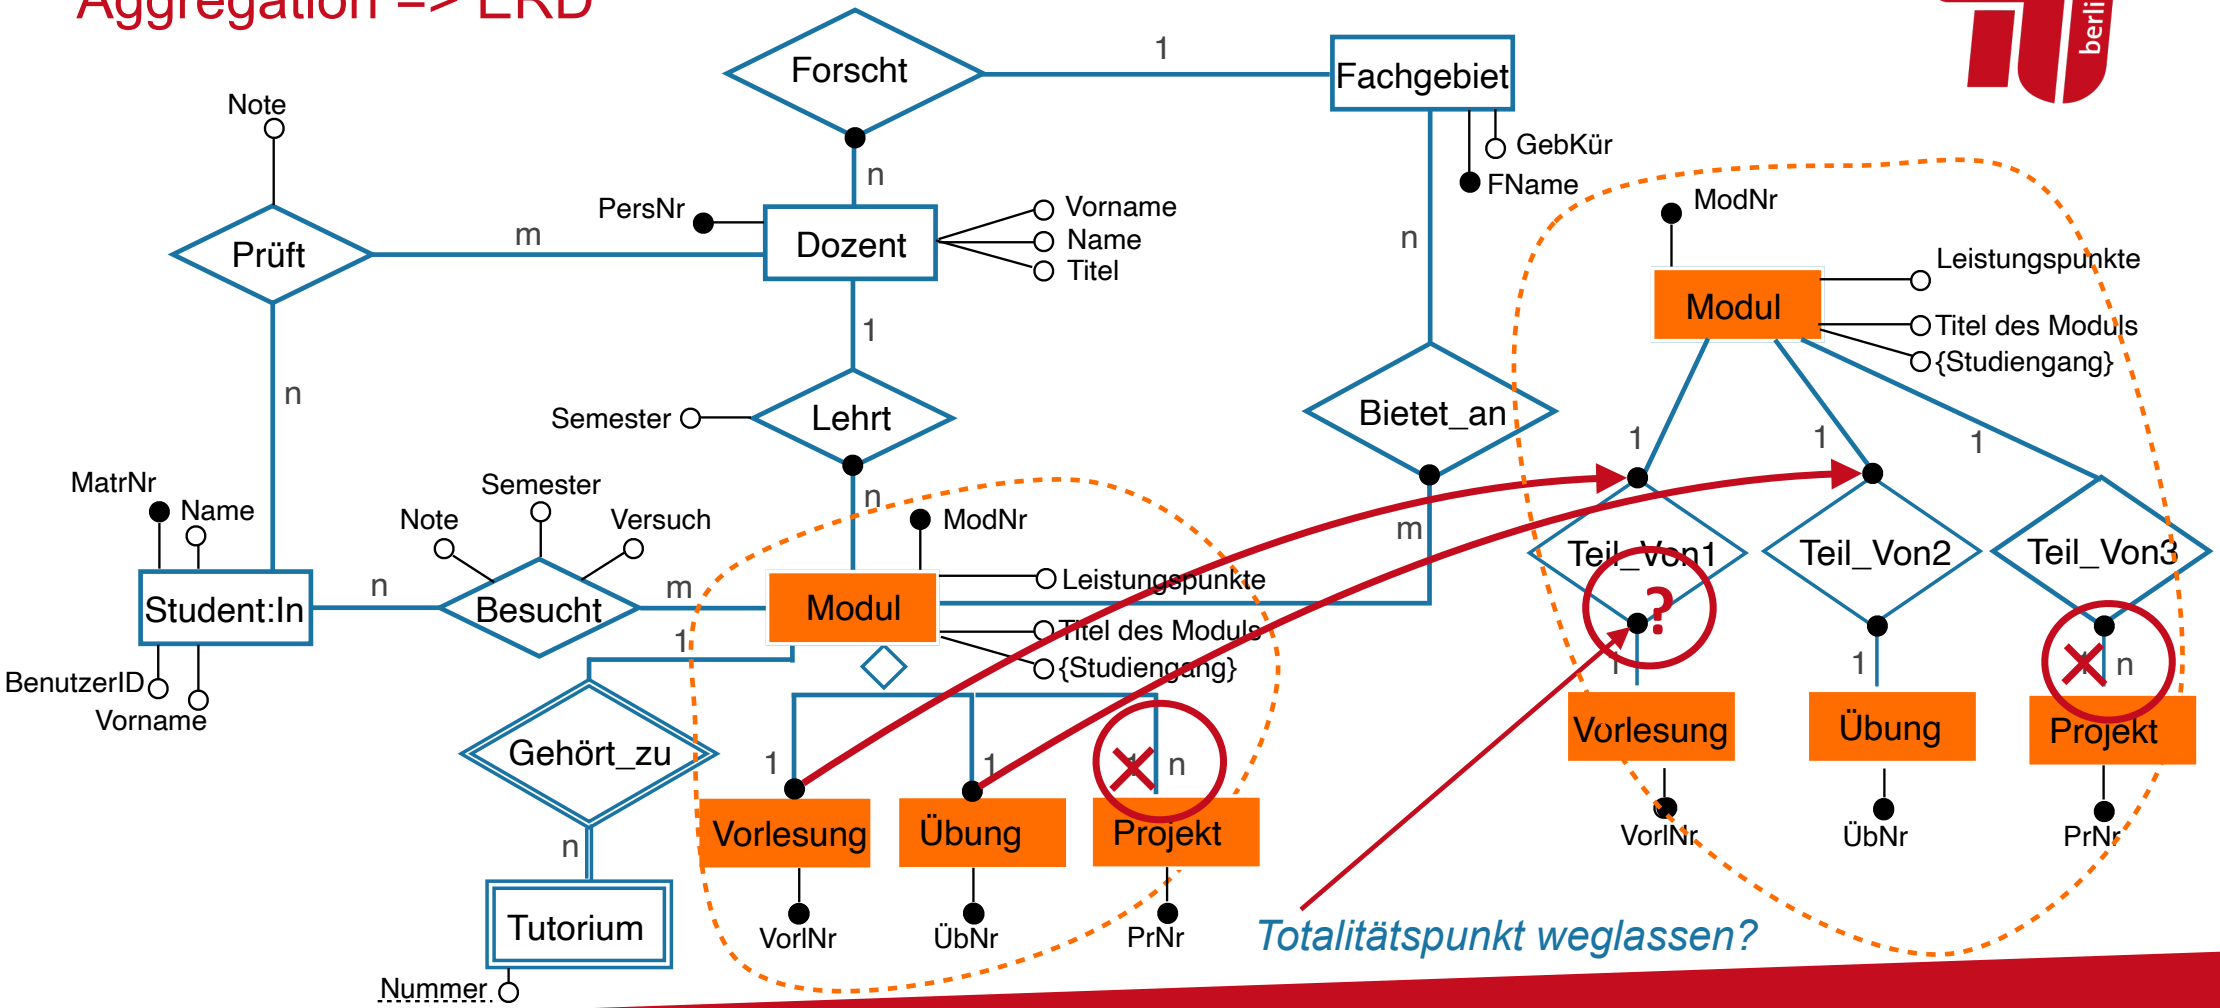

Überblick

- Erweiterte ER-Diagramme (EER-Diagramme)
- Designprinzipien
- Methodik für das konzeptionelles Schema
- Sichtenintegration
- Zusammenfassung und Ausblick

Designprinzipien

- Vorgehensmodell für die konzeptionelle Ebene gemäß Drei-Schichten Architektur
  - Konzeptioneller Datenbankentwurf (ER-Modellierung) in 3 Phasen:
    - frühe, mittlere und späte Entwurfsphase
  - Logischer Datenbankentwurf (Schema der Datenbank, ggf. Normalisierung)
  - Umsetzung in eine Implementierung (Datendefinition in DBMS-Sprache

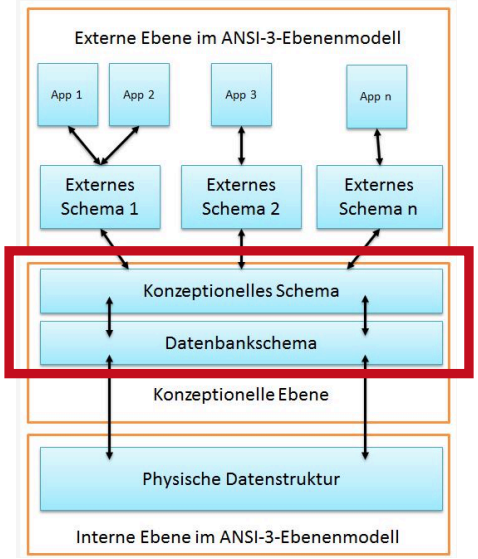

- Konkrete Grundprinzipien beim ER- bzw. EER-Entwurf
  - Treue zur Anwendung
  - Vermeidung von Redundanz
  - Einfachheit
  - Überlegte Entscheidung zwischen Entity-Typen und Attributen
  - Sparsamer Einsatz von Relationship-Typen
  - Sparsamer Einsatz von schwachen Entitytypen

Vorgehensweise beim konzeptionellen Entwurf

- Folgende Fragen sind dafür zu beantworten:
  - Welche Arbeitsschritte führen eigentlich zum ER-Entwurf?
  - Worauf muss besonders geachtet werden?
  - Wie geht man überhaupt an die Information eines Diskursbereichs heran?
  - Wie skaliert man ER-Modelle (Vergröberung, Verfeinerung)?
  - u.v.a.m.

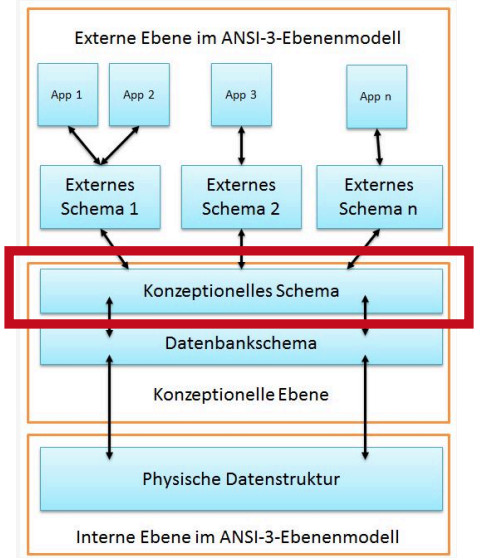

- Wichtige Prinzipien beim Vorgehen sind zu anzuwenden:
  - Entwurfsprozess spiralförmig in mehreren Phasen
  - Zu Beginn des Entwurfs ist die Informationsanalyse durchzuführen
  - Diskussion früher Entwürfe der ER-Diagramme (graphisch!) zum ‘feedback‘ mit dem Auftraggeber/ Kunden

Überblick

- Erweiterte ER-Diagramme (EER-Diagramme)
- Designprinzipien
- Methodik für das konzeptionelles Schema
- Sichtenintegration
- Zusammenfassung und Ausblick

Die frühe Entwurfsphase

... beinhaltet im wesentlichen die grundsätzliche Identifikation der relevanten Information der Miniwelt (oft durch Analyse von Texten wie Anforderungsdefinitionen fachliche Themenbeschreibungen und Ist- wie Soll-Konzepten informationstechnischer Lösungen),

- Analyse der relevanten Begriffe der Miniwelt,

… dabei im einzelnen:

- Klärung/Präzisierung der generellen Zielsetzung der geplanten Datenbankentwicklung und, davon ausgehend, der Informationsanalyse und -modellierung
- erste Identifikation von den wichtigen Begrifflichkeiten ("Dingen") des Diskursbereichs (Entity-Typen) und ihren Eigenschaften und Beziehungen zueinander
- Elimination von (textuellen) Unklarheiten, Doppeldeutigkeiten usw. (Synonyme, Homonyme) ...
- Ausgrenzung der irrelevanten Begriffe (Begründung!)

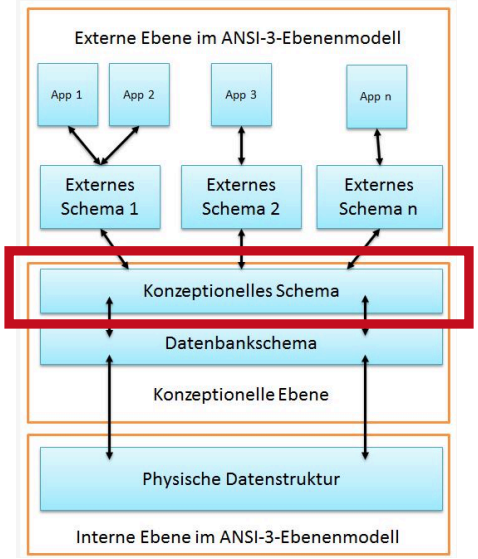

Die frühe Entwurfsphase (Forts.)

... daraus:

- Erstellung eines Glossars der konzeptuell relevanten Begriffe d.h. eine strukturierte, stichwortartige textuelle Beschreibung der wesentlichen Begriffe

... und unmittelbar dabei:

- vorläufige Einteilung dieser Begriffe in Entity-Typen, Attribute und Relationship-Typen

... und ebenfalls parallel dazu:

- Erstellung des ersten Entwurfs eines ER-Diagramms wobei oft schon gewisse Unstimmigkeiten des Glossars oder der Einteilung Entity-Typen vs. Attribute auffallen und zu einer Überarbeitung Anlass geben.

... sowie begleitend (über alle Phasen der Modellierung hinweg!):

- Protokollierung aller wichtigen Diskussionspunkte / Entwurfsentscheidungen

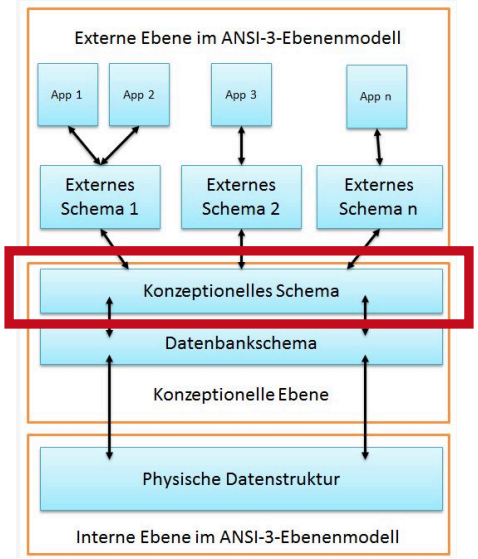

Die mittlere Entwurfsphase

... beinhaltet die weitere Untersuchung der Miniwelt und des bislang entwickelten ER-Modells (der ersten Entwurfs eines ER-Diagramms) in Bezug auf:

- Sichtenintegration (Präzisierung und ggf. Revision) der zuvor entworfenen Begrifflichkeit durch Analyse und Hinzufügen weiterer Eigenschaften und Beziehungen

… und damit zusammenhängend

- Analyse und Darstellung von Integritätsbedingungen

… sowie

- Untersuchung des Modells auf mögliche Abstraktionen durch Verwendung geeigneter Abstraktionskonzepte (Generalisierung/Spezialisierung bzw. Aggregation)

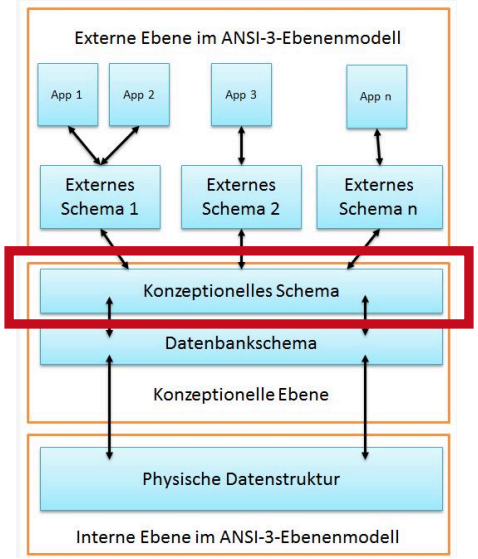

Die späte Entwurfsphase

... setzt den in den vorhergehenden Phasen begonnenen Prozess konsequent fort und liefert als Ergebnis den kompletten konzeptionellen DB-Entwurf (als ER- oder EER-Diagramm) mit allen Begleitdokumenten:

- durch die bereits vorliegenden oder neu erstellen textuellen Beschreibungen / Anforderungsdefinitionen,
- durch das als graphische Repräsentation ER-Diagramm (oder EER-Diagramm) mit verfeinerten Integritätsbedingungen (ggf. durch Erweiterung der Notation und textuelle Ergänzungen) und verfeinerten sowie ggf. typisierten Attributen,
- das Begriffsglossar, das seinerseits ergänzt wird durch textuelle Beschreibungen beispielsweise von funktionalen und dynamischen Zusammenhängen oder durch erläuternde Instanz-Beispiele,
- sowie das (oftmals separat geführte, z.T. auch in das Glossar integrierte) Protokoll der Entwurfsentscheidungen

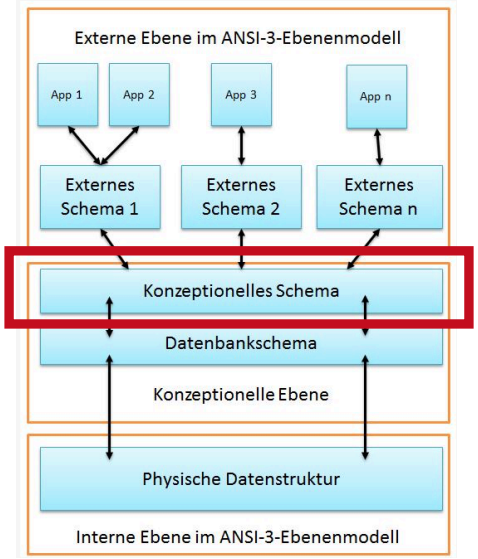

Überblick

- Erweiterte ER-Diagramme (EER-Diagramme)
- Designprinzipien
- Methodik für das konzeptionelles Schema
- Sichtenintegration
- Zusammenfassung und Ausblick

Konsolidierung von Teilschemata oder Sichtenintegration

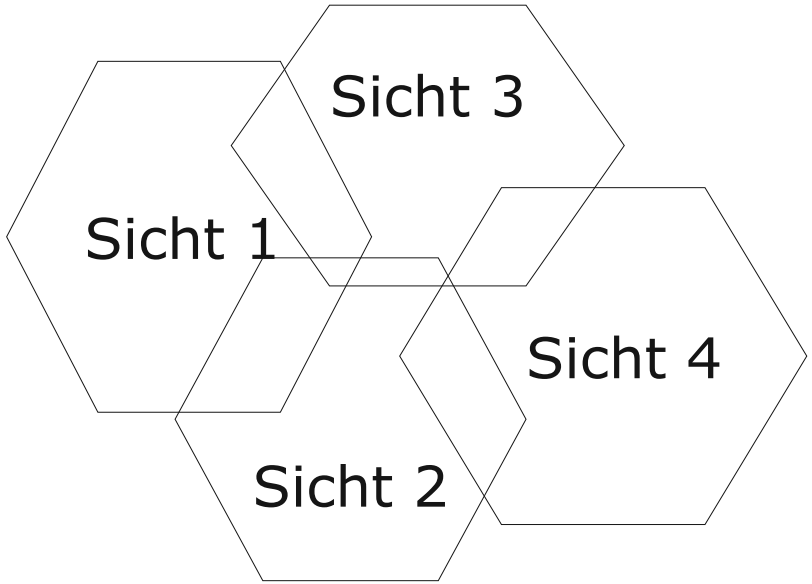

Konsoli-
dierung →

Globales Schema

- Redundanzfrei
- Widerspruchsfrei
- Synonyme bereinigt
- Homonyme bereinigt
- Strukturelle Konflikte bereinigt

Integrationskonflikte

- Namenskonflikte
  - Homonyme: Schloss; Hahn; Kunde
  - Synonyme: Auto, KFZ, Fahrzeug
- Typkonflikte
  - verschiedene Strukturen für das gleiche Element, z.B. Attribute
- Wertebereichskonflikte
  - verschiedene Wertebereiche für ein Element
- Bedingungskonflikte
  - In Sichten werden unterschiedliche Integritätsbedingungen angegeben, z.B. verschiedene Schlüssel für ein Element

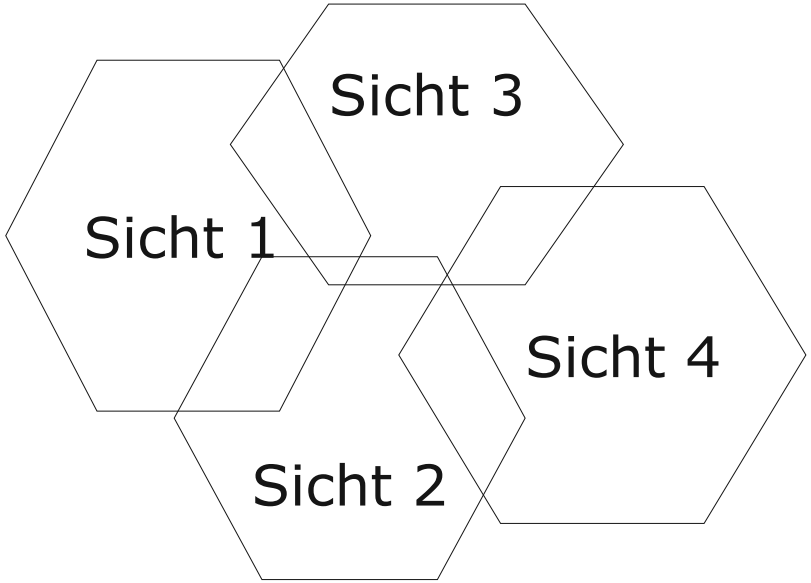

Möglicher Konsolidierungsbaum

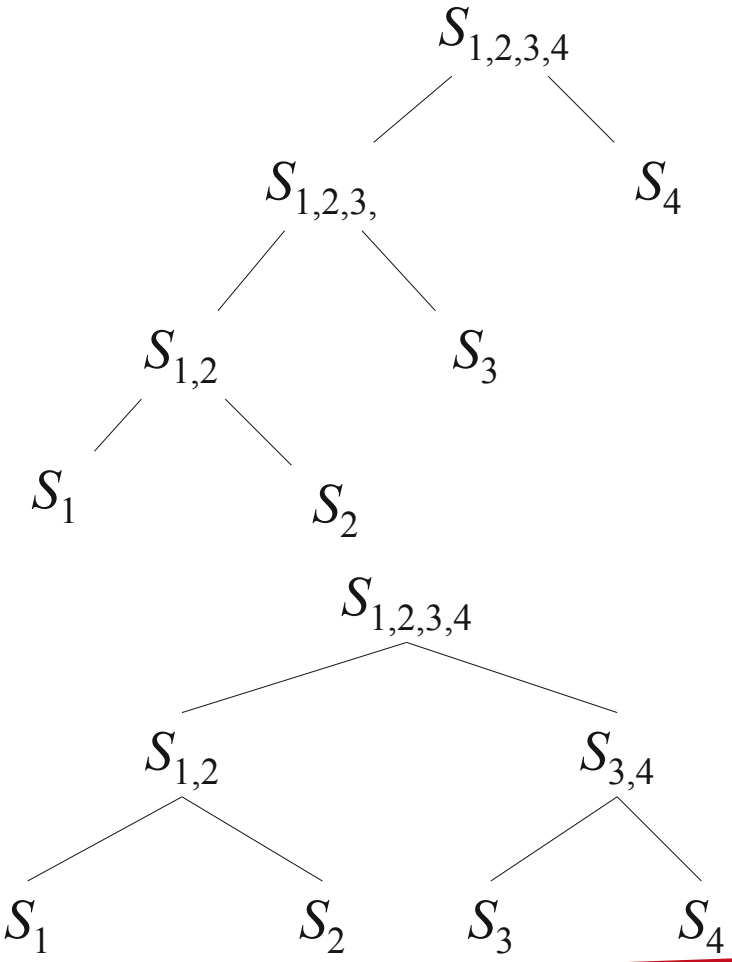

- Mögliche Konsolidierungsbäume zur Herleitung des globalen Schemas $S_{1,2,3,4}$ aus 4 Teilschemata S_1, S_2, S_3, und S_4
  - Maximal hoher Konsolidierungsbaum
    - „links-tief“ (left-deep)
  - Minimal hoher Konsolidierungsbaum
    - Balanciert
  - Hybrides Vorgehen
- Beide Vorgehensweisen haben Vor- und Nachteile.

Sichtenintegration: Beispiel

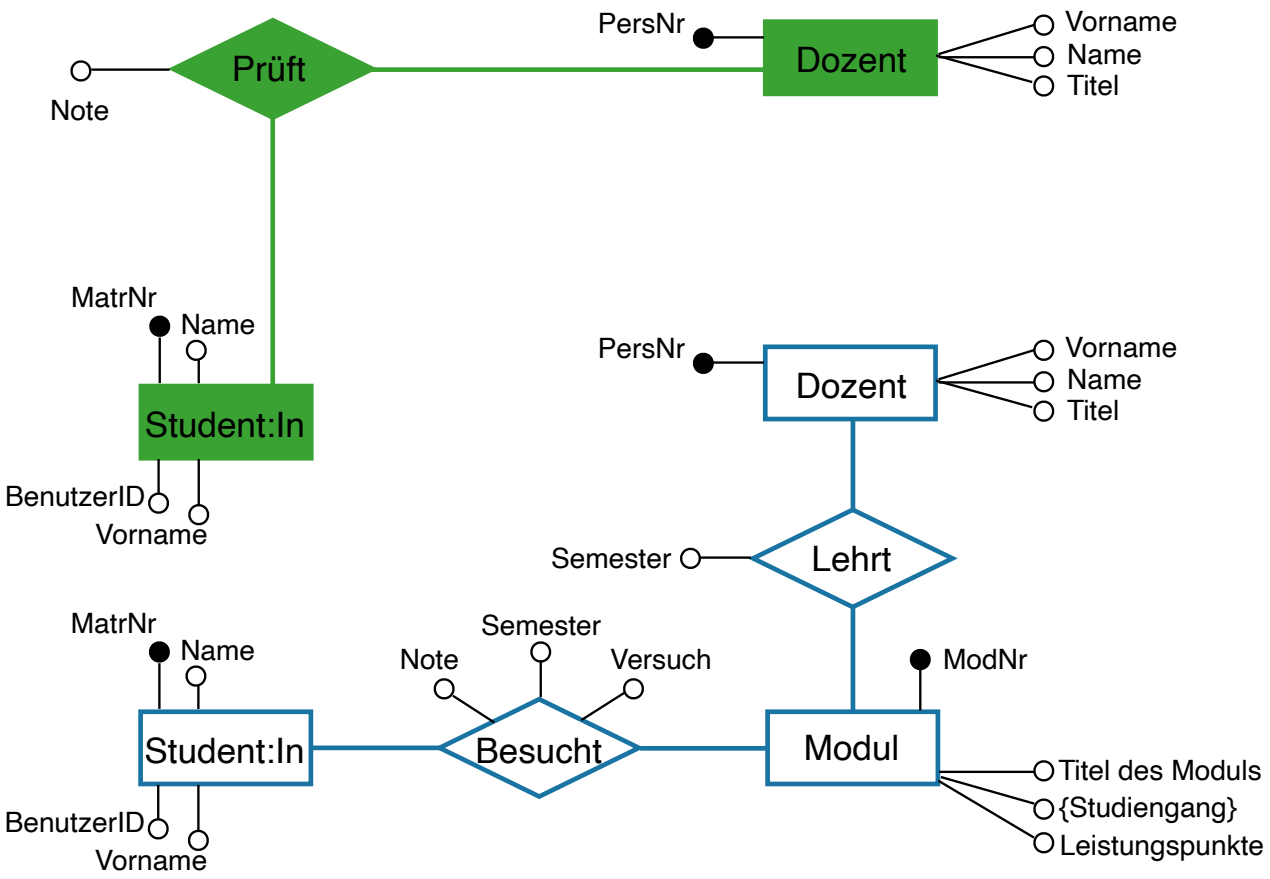

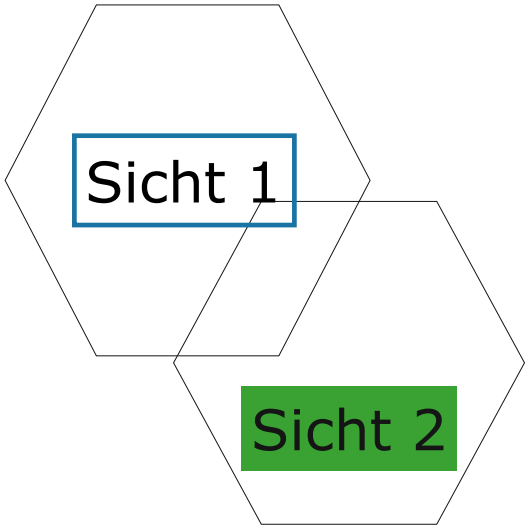

Sichtenintegration: Beispiel

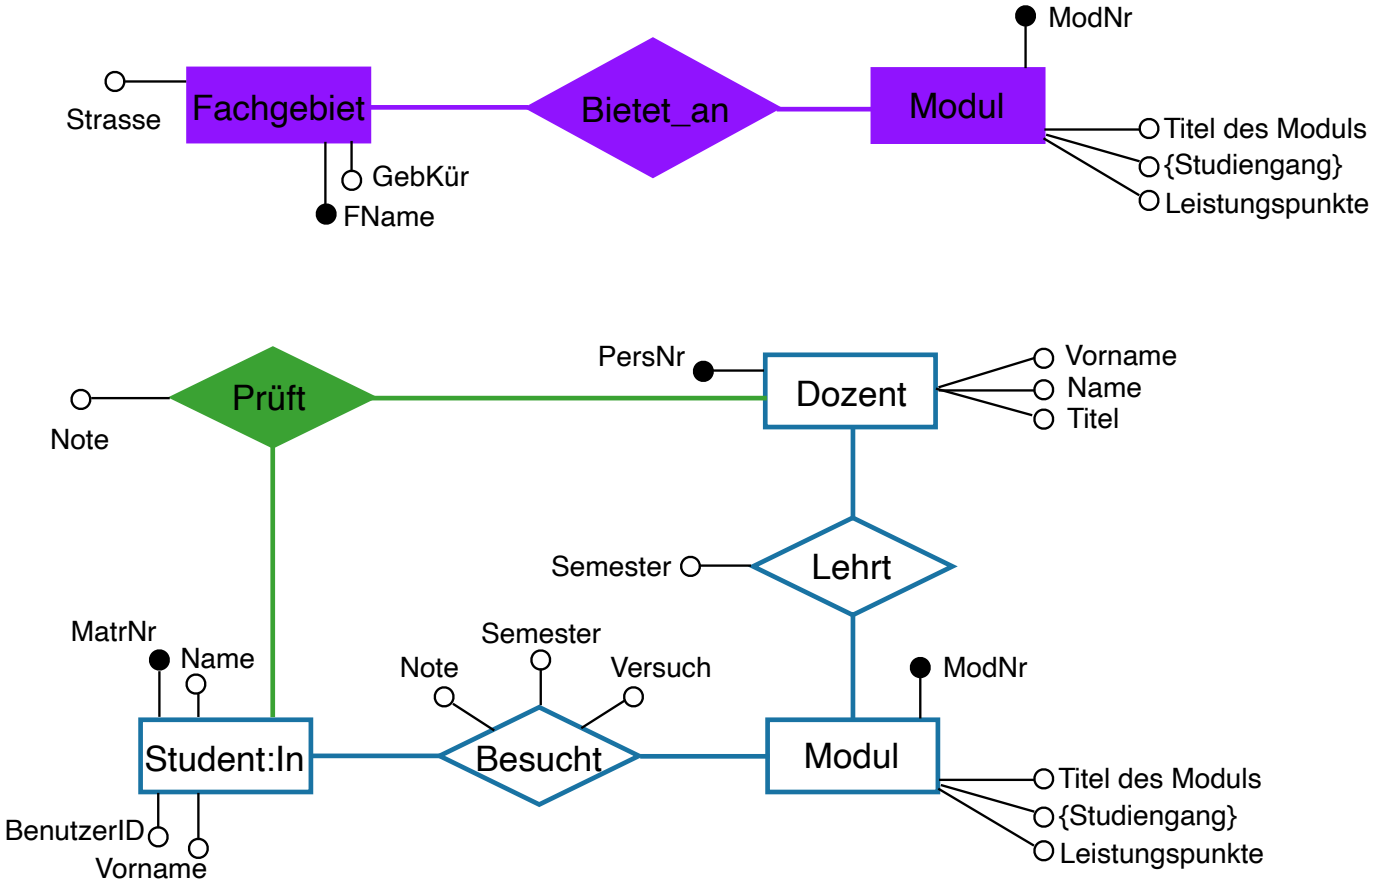

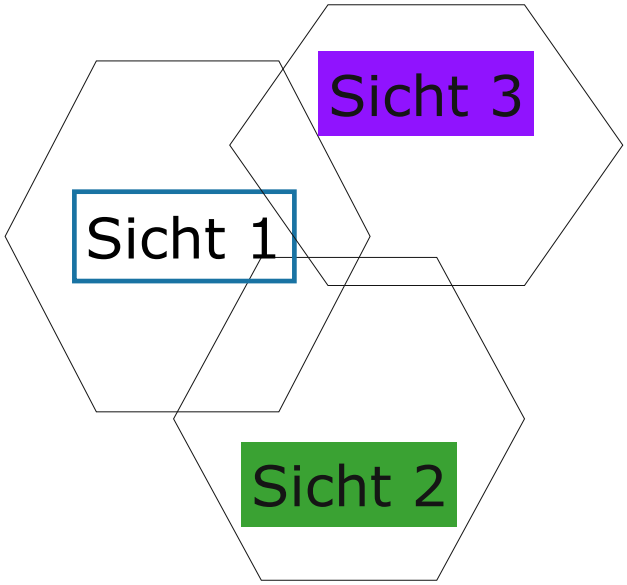

Sichtenintegration: Beispiel

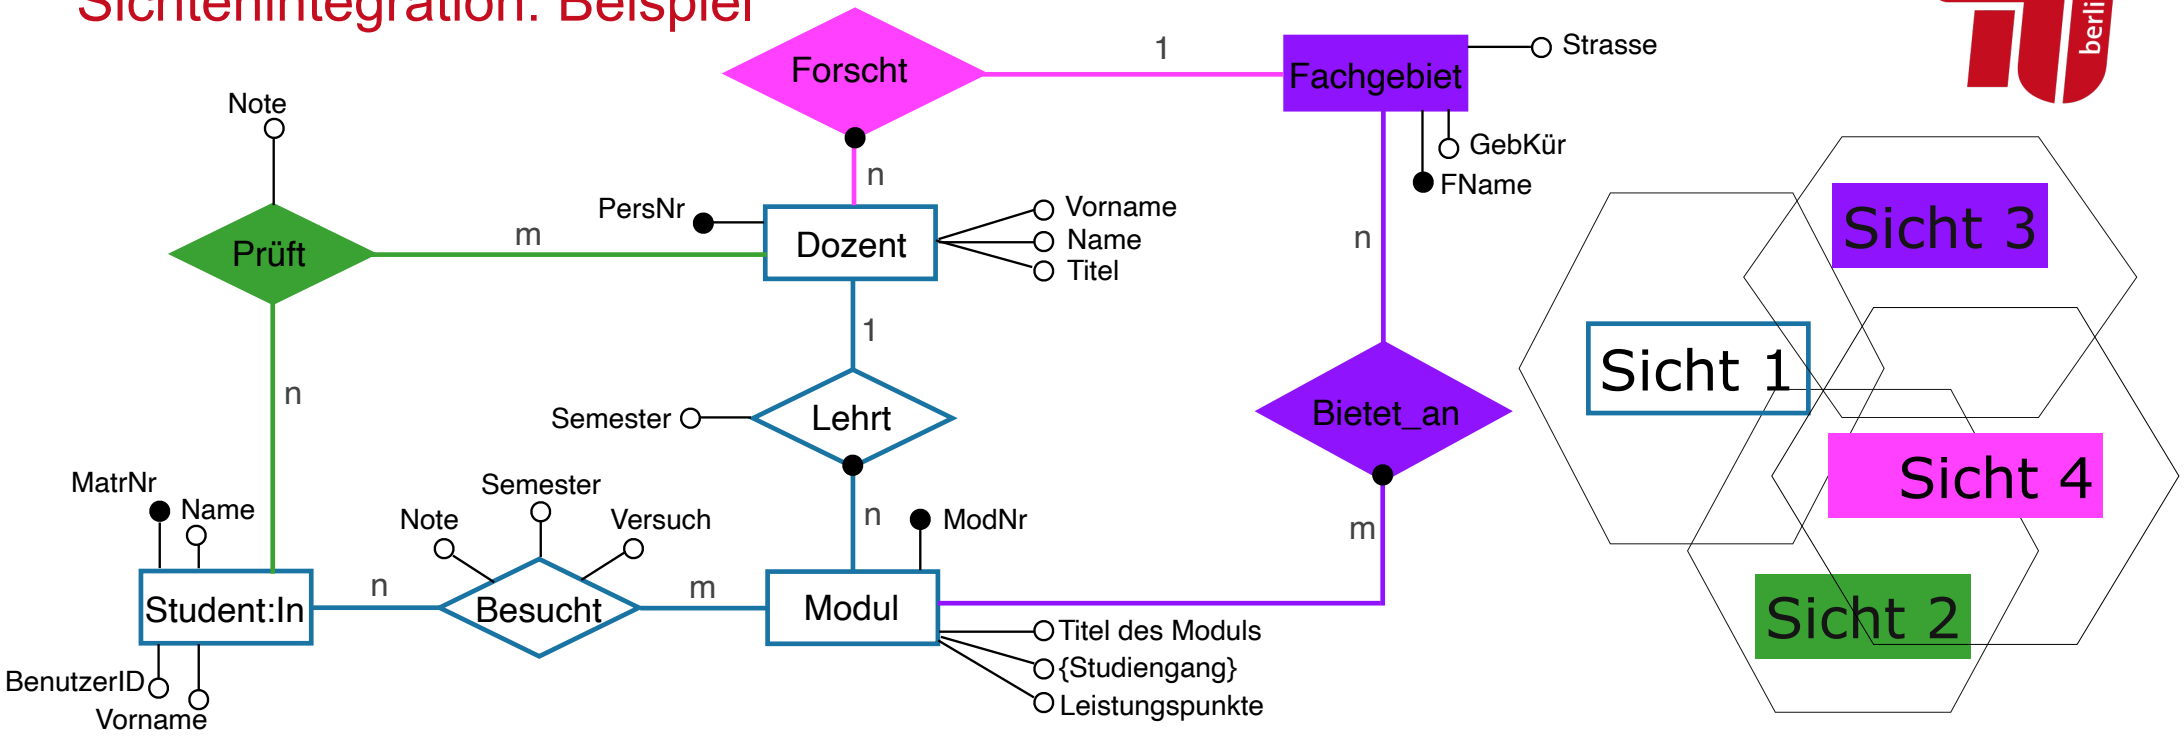

EER-Diagramm, Glossar und Entwurfsentscheidungen mit drawio.io

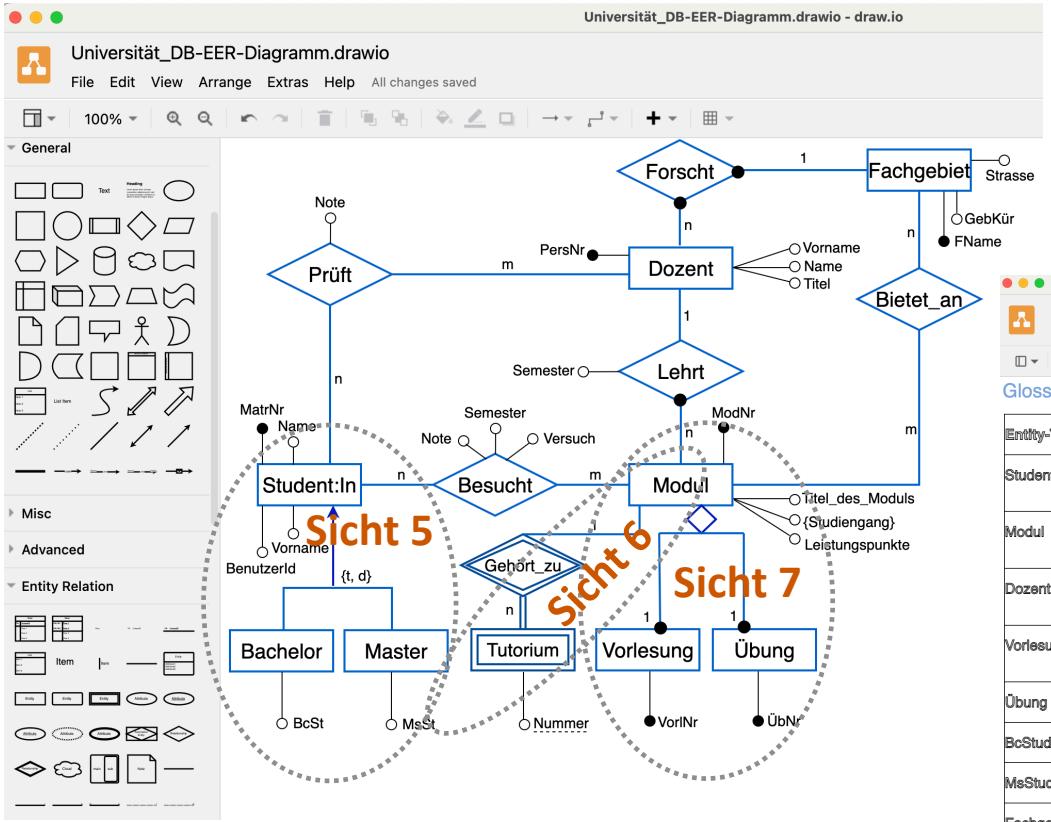

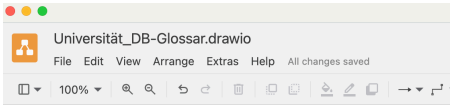

Glossar

Entity-Typ	Attribute	Beschreibung
Student:In	MatrNr, Name	Das sind Studierende, welche die Module an der Universität besuchen
Modul	ModNr, MName	Module werden durch Dozenten geleitet
Dozent	PNr, Name	Dozenten leiten Module und prüfen die Studenten
Vorlesung	VorlNr	Vorlesung ist Bestandteil eines Moduls
Übung	ÜbNr	Übung ist Bestandteil eines Moduls
BcStudent	MatrNr, BcSg	Bachelor Student ist ein Studierende
MsStudent	MatrNr, MsSg	Master Student ist ein Studierende
Fachgebiet	FName, GebKür, Strasse	Fachgebiete anbieten Module. Dozenten forschen an Fachgebieten
Tutorium	Nummer	Tutorien gehören zu Modulen

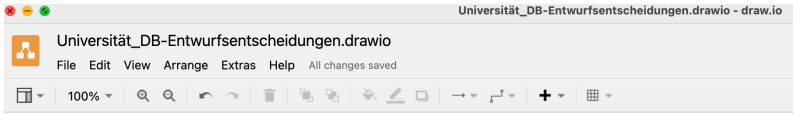

Entwurfsentscheidungen

- Matrikelnummer (MatrNr) ist notwendig um einen Studenten eindeutig zu identifizieren.

Schlüssel von Student:In

- MatrNr ist eine sechsstellige natürliche Zahl mit dem Wertebereich zwischen 100000 und 999999.

Wertebereich

- Jedes Modul muss von einem Dozenten geleitet werden.

Totalität am Modul

- An jedem Modul müssen mindestens 3 Studenten teilnehmen:
$\forall m \in Modul : |\{(s, m) \in Besucht \mid s \in Student\}| \geq 3$

Komplexe IBs (Constraints, Trigger, etc.)

- Student wird im dritten Versuch grundsätzlich nur von dem Dozenten geprüft, der das nichtbestandene Modul geleitet hat.

- Im dritten Versuch gibt es immer zwei prüfungsberechtigte Dozenten.

Überblick

- Erweiterte ER-Diagramme (EER-Diagramme)
- Designprinzipien
- Methodik für das konzeptionelles Schema
- Sichtenintegration
- Zusammenfassung und Ausblick

Zusammenfassung der Schlüsselkonzepte

Konzept	Erläuterung
Generalisierung/Spezialisierung	ist ein Konzept zur vertikalen Strukturierung der Anwendung aufgrund der gemeinsamen Eigenschaften (Attribute). Die vertikale Beziehung ist “Ist-Ein(e)-Von”.
Integritätsbedingungen der Generalisierung/Spezialisierung	Man unterscheidet die Völlständigkeits_Einschränkung sowie Disjunkheits-Einschränkung: • {total, disjunkt} • {total, überlappend} • {partiell, disjunkt} • {partiell, überlappend}
Aggregation	ist ein Konzept zur vertikalen Strukturierung der Anwendung aufgrund der Zugehörigkeit einziger Teile zu Ganzem. Die vertikale Beziehung ist “Ist-Teil-Von”.
Kardinalität/Totalität der Aggregation	Es gibt nur 1:n und 1:1-Kardinalität mit genauer Angabe sowie Totalität, die hinweist, dass jede Entität zu jeder Ausprägung des Aggregates gehört.
Designprinzipien	Treue zur Anwendung, Vermeidung von Redundanz, Einfachheit, Sparsamkeit an RT, ET.
Drei Entwurfsphase	es handelt sich die frühe Phase (Informationsanalyse und erster Entwurf des EER-Diagramm), die mittlere Phase (Sichtenintegration, IBs und Abstraktionen) und der späten Phase (EER-Diagramm + Glossar + Entwurfsentsdcheidungen.
Sichtenintegration	Mögliche Konsolidierungsbäume zur Herleitung des globalen Schemas.

Zusammenfassung und Ausblick

Das Wichtigste in Kürze:

- Abstraktionskonzepte und erweiterte ER-Diagramme
- Generalisierung/Spezialisierung und Aggregation
- Sichtenintegration und Designprinzipien
- Drei Phasen der Methodik für den konzeptionellen Entwurf
- Literaturhinweis für heute
  => **[1]** *Kapitel 4 und Kapitel 11*

In der nächsten Veranstaltung:

Relationaler Entwurf

- Bitte lesen Sie zur Vorbereitung:
  => *Kap. 2 und Kap. 4 des Lehrbuches*

2. The Relational Model of Data

2.1 An Overview of Data Models

2.2 Basics of the Relational Model

4. High-Level Database Models

4.5 From E/R Diagrams to Relational Designs

4.6 Converting Subclass Structures to Relations

Anhang 1: Semantik der Grundkonzepte (Forts.)

- Mathematische Formalisierung, d.h. (Form-) Semantik oder Interpretation der Konzepte der EER-Modellierung stellt auf eine sichere Grundlage die (graphische) Modellierungstechnik mit den Konzepten:
    - Generalisierung
    - Aggregation
- Hierzu reichen im wesentlichen die allseits bekannten Grundbegriffe Menge, Relation, Abbildung sowie deren Eigenschaften und etwas Prädikatenlogik aus.

Semantik der Generalisierung

- Ein durch die Generalisierungsabstraktion gebildeter abstrakter Entity-Typ wird (wie einfache Entity-Typen) durch eine Menge interpretiert. Für den generalisierten Entity-Typ und seine Spezialisierungen gelten folgende Teilmengenbeziehungen:

  Sei G ein durch Generalisierung über den konstituierenden Entity-Typen $E_1, E_2, \ldots, E_n$ gebildeter abstrakter Entity-Typ und seien $E_1, E_2, \ldots, E_n$ und G die jeweiligen Interpretationen.

  Dann gilt: $E_1 \subseteq G, E_2 \subseteq G, \ldots, E_n \subseteq G$

  Seien $A_i = \{ a(i,1), a(i,2), \ldots a(i,k) \}$ die Attribute des Entity-Typs E_i, A die des Entity-Typs G.

  Dann gilt: $A_i \supset A$ (generell „echte“ Obermenge)

  Falls ein konstituierender Entity-Typ E_i einen eigenen Relationship-Typ zu einem anderen Entity-Typ hat, kann dieser keine eigene Attribute haben.

Semantik der Aggregation

- Aus den vorangegangenen Betrachtungen wird deutlich, dass sich die Aggregation mathematisch als (kartesische) Produktbildung darstellt — ähnlich zur Semantik von Relationship-Typen.
- Unterschiedlich behandelt werden müssen lediglich mengenwertige vs. **einfache** Aggregationen, da sich hier einfache Tupel von solchen unterscheiden, bei denen einzelne Komponenten mehrere Elemente enthalten können.
- Sei A durch Aggregation über den Entity-Typen $E_1, \ldots E_k, E_{k+1}, \ldots E_n$ entstandener abstrakter Entity-Typ, wobei o.B.d.A. die E_i $(1 \leq i \leq k)$ einfach und die E_j $(k+1 \leq j \leq n)$ mengenwertig aggregiert werden.
- Dann ist

$$A := E_1 \times \ldots \times E_k \times \wp(E_{k+1}) \times \ldots \times \wp(E_n)$$

die Menge aller möglichen Aggregate auf der Seite der Semantik, die über den Interpretationen $E_1 \ldots E_n$ der Entity-Typen $E_1, \ldots, E_n$ gebildet werden können.

Bem. $\wp(E)$ *bezeichnet hier wie üblich die Potenzmenge von* E*, d.h. die Menge aller Teilmengen von* E*.*
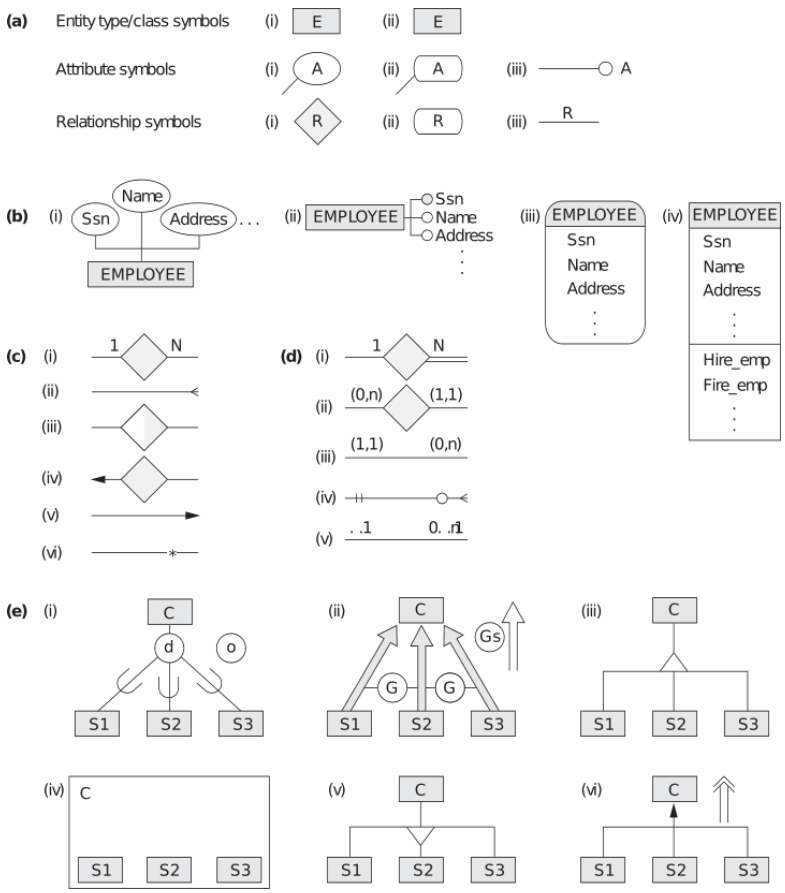
Anhang 2: Weitere Notationen