MIXED SIGNAL
MSC
CIRCUIT DESIGN

Technische Universität Berlin

Rechnerorganisation

Einstein-Prof. Dr.-Ing. Friedel Gerfers

Kapitel 6: Rechenleistung

Ziele

Nach diesem Kapitel sollten Sie in der Lage sein...

- *Rechenleistung* zu *messen*, zu protokollieren und zusammenzufassen
- Intelligente Entscheidungen zu treffen
- den *Marketing-Hype* zu *durchblicken*
- *Ausführungszeit* bei gegebener Anzahl der Befehle, Cycles Per Instruction (CPI) und Taktfrequenz zu *berechnen*
- Gesetz von Amdahl anzuwenden
- Eine bekannte *Benchmark-Suite benennen* zu können

Rechenleistung

Fragen dieser Vorlesung:

- Warum ist manche Hardware für bestimmte Programme besser geeignet als andere?
- Welche *Faktoren der Systemleistung* sind hardwarebezogen? (Brauchen wir neue Hardware oder ein neues Betriebssystem?)
- Wie beeinflusst der *Maschinenbefehlssatz* die Rechenleistung?

Inhalt

- Rechenleistung definieren
- Antwortzeit versus Durchsatz
- CPU-Zeit
- CPU-Leistungsgleichung
- Rechenleistung vergleichen
- Benchmarks
  - SPEC
  - Intel Pentium SPEC performance
- Gesetz von Amdahl
- MIPS und MFLOPS

Rechenleistung definieren

- Welches Flugzeug hat die beste Leistung?

Flugzeug	Passagiere	Reichweite (Meilen)	Geschwindigkeit (Miles Per Hour)
Boeing 737-100	101	630	598
Boeing 747	470	4150	610
Concorde	132	4000	1350
Douglas DC-8-50	146	8720	544

- Abhängig von der Bewertung
  - Welcher ist der schnellste Flug nach New York? [→Latenz (*Latency*)]
  - Wie bekommt man am schnellsten 300 Menschen nach New York? [→Durchsatz (*Throughput*)]

Rechenleistung: ZEIT, ZEIT, ZEIT

- Antwortzeit (*response time, latency*)
  - Wie lange dauert es, bis mein *Job* ausgeführt wird?
  - Wie lange dauert es, einen *Job* auszuführen?
  - Wie lange muss auf eine Datenbankabfrage gewartet werden?

- Durchsatz (*throughput*)
  - Wie viele *Jobs* können gleichzeitig auf der Maschine ausgeführt werden?
  - Wie viel Arbeit – Rechenoperation werden erledigt?

- *Wenn eine Maschine einen neuen (schnelleren) Prozessor bekommt: Was erhöht sich?*

CPU-Zeit

- Verstrichene Zeit (*elapsed time*)
  - Zählt alles *(Platten- und Speicherzugriffe, I/O , etc.)*
  - Eine brauchbare Zahl, aber selten gut zum Vergleichen
- CPU-Zeit
  - Zählt weder I/O, noch die Ausführungszeit anderer Programme
  - Kann in System- und Benutzer-CPU-Zeit zerlegt werden
- Unser Fokus: Benutzer-CPU-Zeit
  - Zeit, die zur Ausführung von Code-Zeilen, die „in“ unserem Programm sind, verwendet wird
- Ausgabe des Unix-Kommandos `time`:

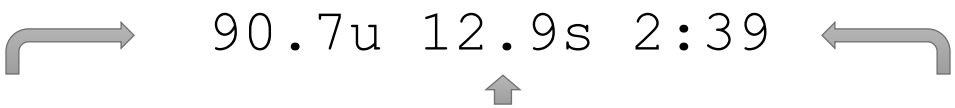

Benutzer-CPU-Zeit System-CPU-Zeit Verstrichene Zeit

CPU-Leistungsgleichung

$$T = N_{instr} \cdot CPI \cdot t_{cycle} = \frac{N_{instr} \cdot CPI}{f}$$

wobei

- N_{instr} = Anzahl vom Programm benötigter Maschinenbefehle
- *CPI* = (durchschnittliche) Taktzyklen pro Maschinenbefehl (*Cycles Per Instruction*)
- t_{cycle} = Taktzykluszeit (*cycle time*)
- f = Taktfrequenz = $1/t_{cycle}$
- Ein 4-GHz-Takt hat eine Taktzykluszeit von ..... ?

$$\frac{1}{4 \cdot 10^9}\,\mathrm{s} = 250 \cdot 10^{-12}\,\mathrm{s} = 250\,\text{Picosekunden (ps)}$$

CPI Beispiel

- Ein 2-GHz-Prozessor (Mehrzyklenprozessor) führt ein Programm mit 5 Millionen Befehlen aus:
  - 52% sind arithmetische Befehle, die jeweils 4 Taktzyklen benötigen
  - 25% sind Ladebefehle, die jeweils 5 Taktzyklen benötigen
  - 10% sind Speicherbefehle, zu je 4 Taktzyklen
  - 11% sind Verzweigungen, zu je 3 Taktzyklen
  - 2% sind Sprünge, zu je 3 Taktzyklen

- Wie ist der *CPI*-Wert des Programms?
  - $CPI = 0.62 \cdot 4 + 0.25 \cdot 5 + 0.13 \cdot 3 = 4.12$
- Wie ist die Ausführungszeit?
  - $N_{instr} \cdot CPI / f$
  - $5 \cdot 10^6 \cdot 4.12 / (2 \cdot 10^9\ \text{Hz}) = 5 \cdot 10^6 \cdot 4.12 * 500 \cdot 10^{-12}\ \text{s} = 10.3\ \text{ms}$

Leistungsfähigkeit verbessern

- Die CPU-Leistungsgleichung zeigt, wie die Leistungsfähigkeit eines Prozessors gesteigert werden kann

$$T = N_{instr} \cdot CPI \cdot t_{cycle}$$

- Zur Erhöhung der Leistungsfähigkeit (alles andere bleibt gleich) können wir ... (*erhöhen* oder *verringern*?)
  - Die Zahl der nötigen Taktzyklen eines Programms _verringern_, oder
  - Die Taktzykluszeit _verringern_ oder, anders gesagt,
  - Die Taktfrequenz _*erhöhen*_.

Leistungsfähigkeit verbessern

$$T = N_{instr} \cdot CPI \cdot t_{cycle}$$

- Wie können wir was verbessern?

	Befehlsanzahl	CPI	Zykluszeit
Programm	X	(X)	
Compiler	X	(X)	
Befehlssatz	X	X	(X)

Rechenleistung zusammenfassen / 1

- Wenn es nur ein Programm gibt, ist es klar, welcher Computer schneller ist
- Wenn es mehrere Programme gibt, wird es knifflig!
- Beispiel: Annahme P_1 und P_2 werden nur jeweils nur einmal ausgeführt

	Computer A	Computer B	Computer C
Programm P_1 (sek)	1	10	20
Programm P_2 (sek)	1000	100	20
Summe (sek)	**1001**	**110**	**40**

- Summe der Ausführungszeit ist ein konsistentes Auswertungsmaß
  - B ist 9,1-mal schneller als A für die Summe der Programmzeiten P_1 und P_2
  - C ist 25-mal schneller als A (Summe der Programmzeiten P_1 & P_2)

Rechenleistung zusammenfassen / 2

- Zur Bestimmung der Prozessorrechenleistung verwenden wir das arithmetische Mittel verwenden:
  - $Time_i$ Ausführungszeit des Programms P_i
  - n Anzahl Programme

$$\frac{1}{n}\sum_{i=1}^{n} Time_i$$

- Aber wie gehen wir vor, wenn die Programme nicht gleich häufig aufgerufen werden?

- Zwei Herangehensweisen:
  - Gewichtete Ausführungszeit
  - Normalisieren der Ausführungszeiten auf eine Referenzmaschine und Durchschnittsermittlung

Gewichtete Ausführungszeit

- Gewichtete Ausführungszeit:
  - Jedes Programm bekommt einen Gewichtungsfaktor, der relative Ausführungshäufigkeit anzeigt
  - Gewichtungsfaktoren summieren sich zu 1
- Gewichtetes arithmetisches Mittel:

$$\sum_{i=1}^{n} Weight_i \times Time_i$$

- Annahme: $Weight_1$ (P_1) ist 0,8 und $Weight_2$ (P_2) ist 0,2

	Computer A	Computer B	Computer C
Programm P_1 (sek)	1	10	20
Programm P_2 (sek)	1000	100	20
Arithmetisches Mittel (sek)	500,5	55	20
Gewichtetes Mittel (sek)	200,8	28	20

Normalisierte Ausführungszeit

- Ausführungszeit auf eine Referenzmaschine normalisieren
- Durchschnitt ermitteln

	A	B	C
P_1 (sek)	1	10	20
P_2 (sek)	1000	100	20

	Normalisiert auf A			**Normalisiert auf B**			**Normalisiert auf C**		
	A	B	C	A	B	C	A	B	C
P_1 (sek)	1.0	10/1=10.0	20.0	0.1	1.0	2.0	0.05	0.5	1.0
P_2 (sek)	1.0	100/1000= 0.1	0.02	10.0	1.0	0.2	50	5.0	1.0
Arith. Mittel (sek)	**1.0**	5.05	10.01	5.05	**1.0**	1.1	25.025	2.75	**1.0**

- Problem: Das arithmetische Mittel führt je nach Referenz-maschine zu unterschiedlichen Aussagen!
- Lösung: Geometrische Mittel verwenden!!

Geometrisches Mittel

- Benutzen Sie stattdessen das geometrische Mittel:

$$\sqrt[n]{\prod_{i=1}^{n} Ratio_i}$$

geom. Mittel $\sqrt[2]{1 \cdot 9} = 3$

arith. Mittel $\frac{1+9}{2} = 5$

  - $Ratio_i$ = Ausführungszeit von Programm P_i auf der zu bewertende Maschine normalisiert zur Ausführungszeit auf der Referenz-maschine
  - Dieser Wert hat jedoch keine physikalische Bedeutung!

	Normalisiert auf A			**Normalisiert auf B**			**Normalisiert auf C**		
	A	B	C	A	B	C	A	B	C
P_1 (sek)	1.0	10.0	20.0	0.1	1.0	2.0	0.05	0.5	1.0
P_2 (sek)	1.0	0.1	0.02	10.0	1.0	0.2	50	5.0	1.0
Geom. Mittel (sek)	1.0	1.0	**0.63**	1.0	1.0	**0.63**	1.58	1.58	**1.0**

Benchmarks

- Rechenleistung wird am besten durch das Ausführen echter Applikationen bestimmt
  - Typische Programme für den erwarteten *Workload* benutzen, oder
  - typische Applikationen der erwarteten Klasse, z.B.: Compiler/Editoren, Wissenschaftliche Anwendungen, Grafik, etc.
- Kleine Benchmarks
  - Schön für Architekten und Designer
  - Leicht zu standardisieren
  - Können missbraucht werden
- SPEC (*Standard Performance Evaluation Corporation*)
  - Unternehmen haben sich auf Set realer Programme und Eingaben geeinigt.
  - Wertvoller Indikator für Rechenleistung (und Compilertechnologie)
  - Können immer noch missbraucht werden

Benchmark-BUG

*"An embarrassed Intel Corp. acknowledged Friday that a **bug** in a software program known as a compiler had led the company to overstate the speed of its microprocessor chips on an industry benchmark by 10 percent. However, industry analysts said the coding error…was a sad commentary on a common industry practice of "**cheating**" on standardized performance tests…The error was pointed out to Intel two days ago by a competitor, Motorola …came in a test known as SPECint92…Intel acknowledged that it had "optimized" its compiler to improve its test scores. The company had also said that it did not like the practice but felt to compelled to make the optimizations because its competitors were doing the same thing… At the heart of Intel's problem is the practice of "**tuning**" compiler programs to recognize certain computing problems in the test and then substituting special handwritten pieces of code…"*

Saturday, January 6, 1996 New York Times

Compilerverbesserungen

- Compiler-„Verbesserungen“ und Rechenleistung

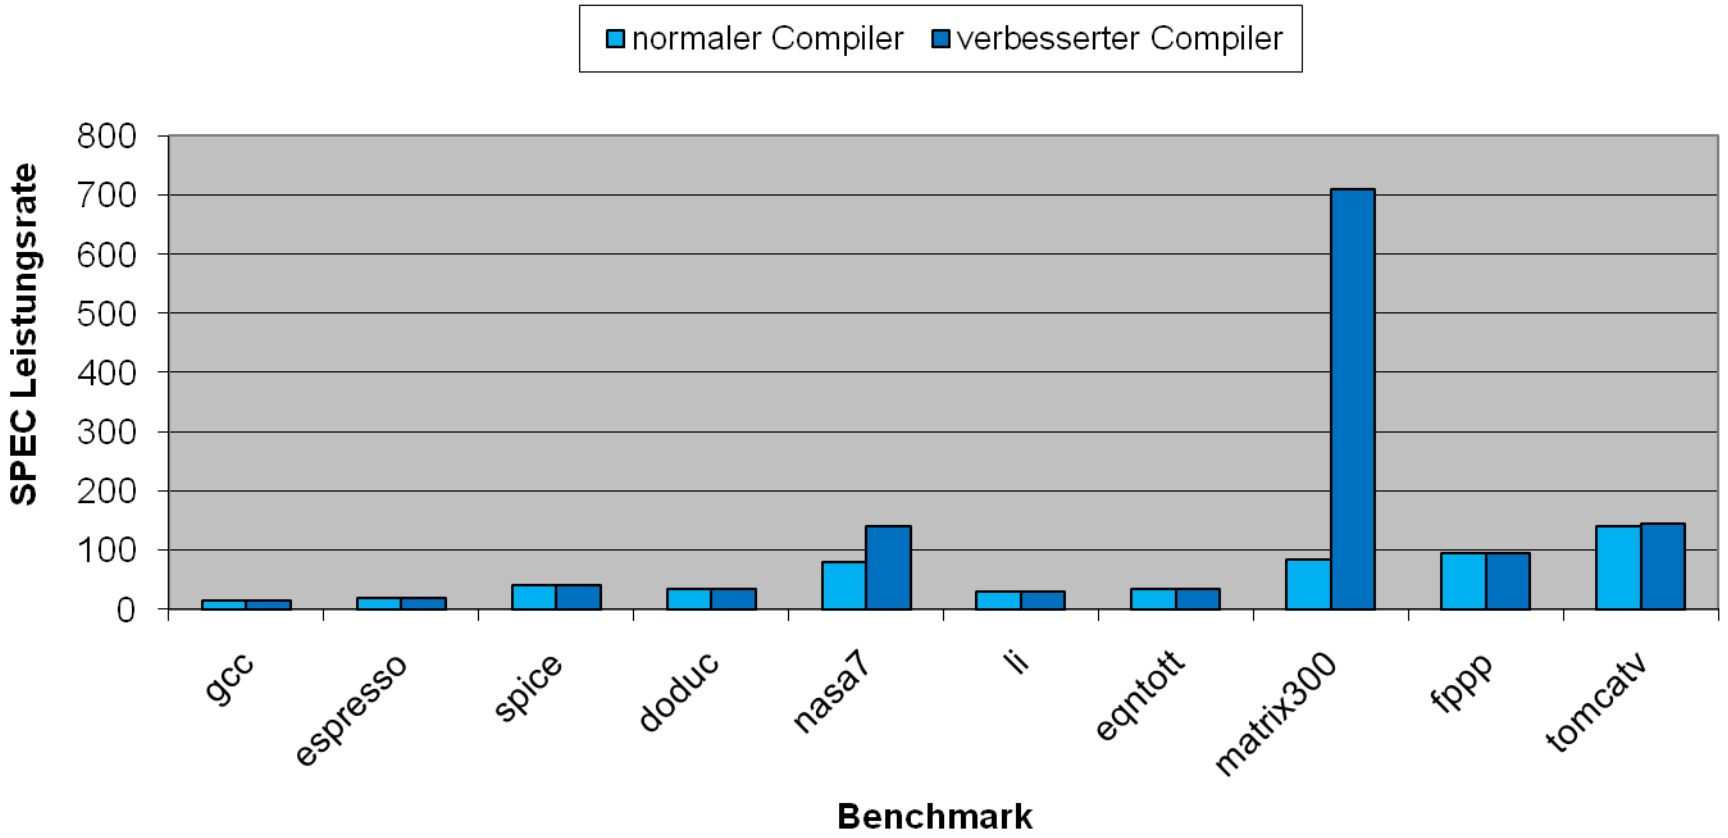

SPEC Mitglieder

- SPEC Mitglieder:
  - Acer Inc. * Action S.A. * Advanced Micro Devices * Apple Inc. * ASUSTeK Computer Inc. * Avere Systems * BlueArc * Bull S.A. * Cisco Systems, Inc. * Citrix Online * CommuniGate Systems * Dell * E4 Computer Engineering SPA * EMC * FORMAT Sp. z o.o. * Fujitsu * Hitachi Data Systems * Hitachi Ltd. * HP * Huawei Technologies * IBM * Incom S.A. * Intel * Itautec S/A * Lenovo * Microsoft * NEC - Japan * Neptuny * NetApp * Novell * NTT System * NVIDIA * Oracle * Parallels * Platform Computing Inc. * Principled Technologies * The Portland Group * QLogic Corporation * Red Hat * SAP AG * SGI * Sun Microsystems * Super Micro Computer, Inc. * Symantec Corporation * Unisys * Via Technologies * Virtustream Ltd. * VMware * WSO2

- Derzeitige CPU Haupt-Benchmark-Suite: SPEC CPU2017

- Webseite: www.spec.org

SPEC CPU

Integer Benchmarks (C und C++)	
Name	**Beschreibung**
gzip	Komprimierung
vpr	FPGA Schaltkreis- und Leiterbahnanordnung
gcc	GNU C-Compiler
mcf	Kombinatorische Optimierung
crafty	Schachprogramm
parser	Textverarbeitungsprogramm
eon	Computervisualisierung
perlbmk	Perl-Anwendung
gap	Gruppentheorie, Interpreter
vortex	Objektorientierte Datenbank
bzip2	Komprimierung
twolf	Ort- und Routensimulation

Gleitkomma-Benchmarks (Fortran und C)	
Name	**Beschreibung**
wupwise	Quanten-Chromodynamik
applu	Parabolische/elliptische partielle Differentialgleichungen
mgrid	3D-Mehrgitterverfahren: Potenzialfeld
swim	Flachwassersimulation
mesa	3D-Grafikbibliothek
galgel	Strömungsmechanik-Simulationen
art	Bilderkennung mit neuronalen Netzen
equake	Simulation Ausbreitung seismischer Wellen
facerec	Bilderkennung von Gesichtern
ammp	Chemische Simulationen
lucas	Primzahlentests
fma3d	Crash-Simulation mit finiten Elementen
sixtrack	Beschleunigerkonstruktion für hochenergetische Atomphysik
apsi	Meteorologie: Schadstoffausbreitung

Leistung vs. Taktfrequenz

- *Führt Verdopplung der Taktfrequenz zur doppelten Rechenleistung?*
- *Kann Maschine mit geringerer Taktfrequenz über bessere Rechenleistung verfügen?*

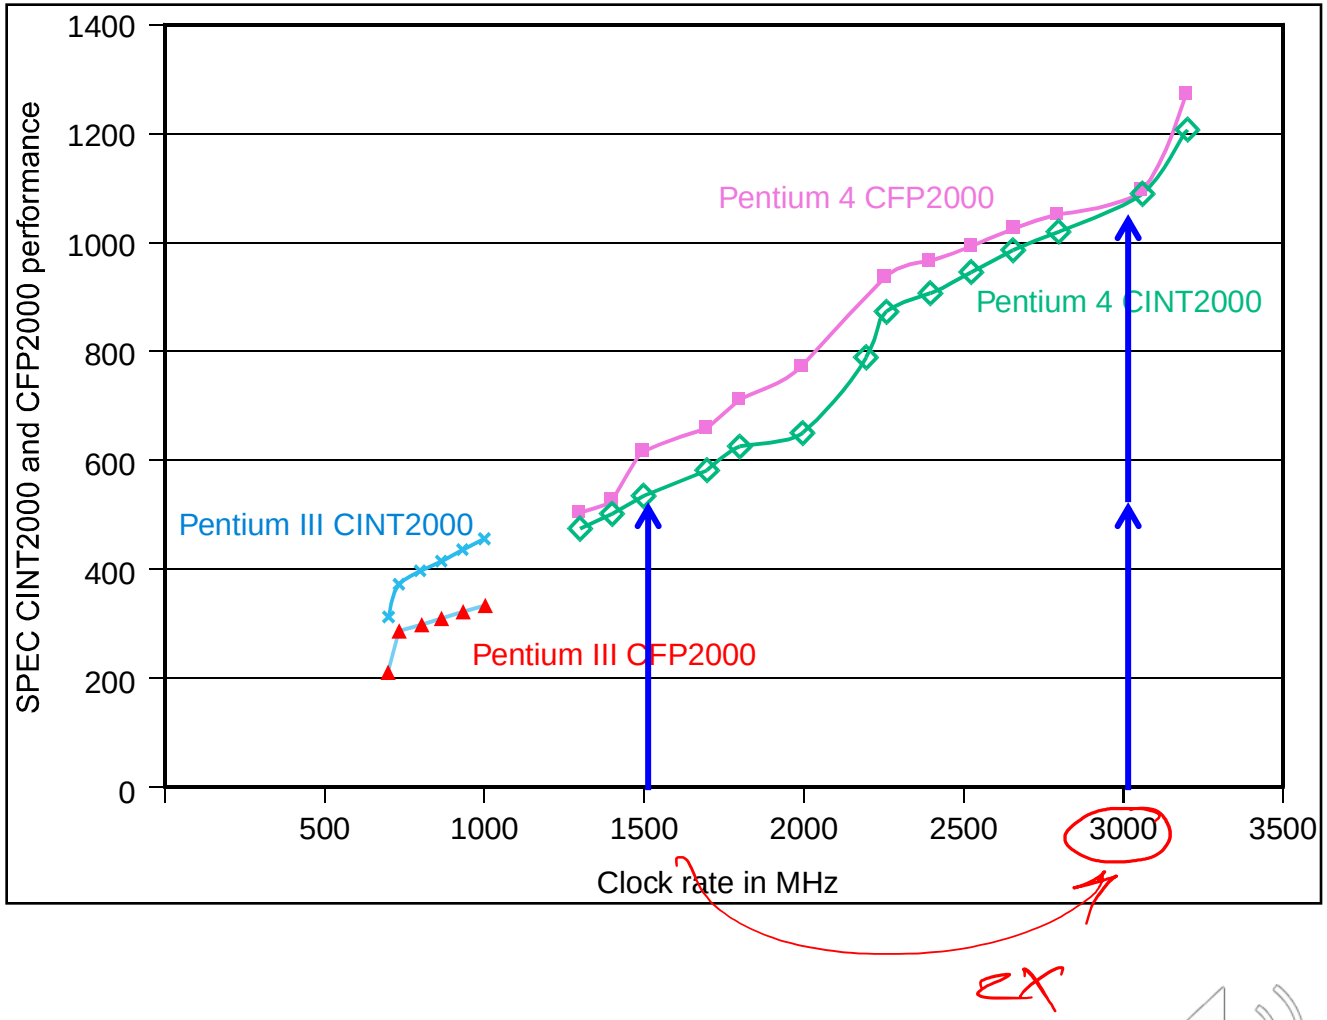

Stromverbrauch und Leistungsfähigkeit

Stromverbrauch ist entscheidende Begrenzung der Leistungsfähigkeit

Bei eingebetteten Systemen ist der Stromverbrauch so wichtig wie Leistungsfähigkeit

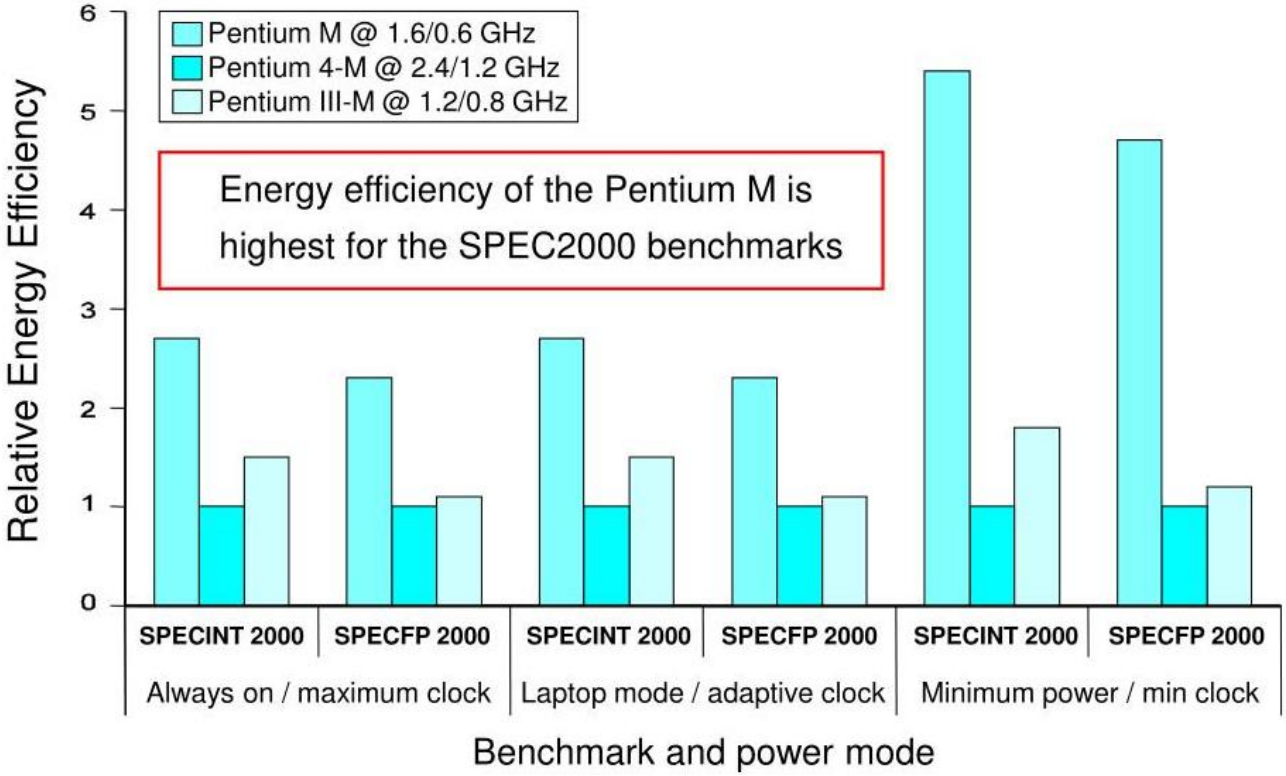

Amdahls Gesetz

- Angenommen wir können Anteil *f* (0 ≤ *f* ≤ 1) der Gesamtausführungszeit, um ein Faktor *x* (x≥1) verbessern d.h. verkürzen, wie hoch wird der gesamte Speedup *S* sein?

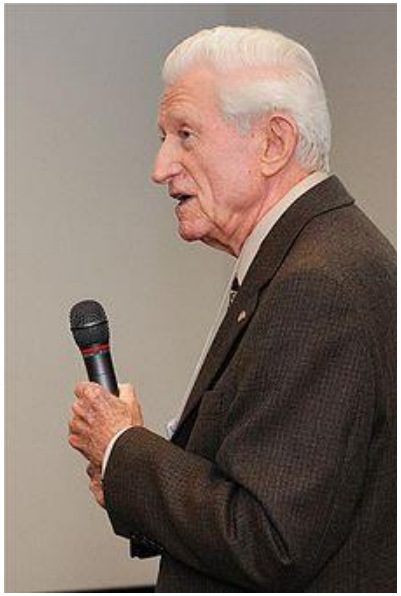

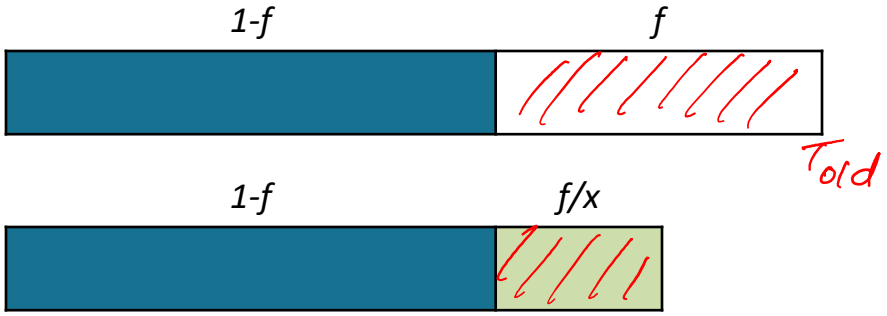

$$\Rightarrow T_{new} = (1-f)T_{old} + \frac{fT_{old}}{x}$$

$$S = \frac{T_{old}}{T_{new}} = \frac{T_{old}}{(1-f)T_{old} + (f/x)T_{old}} = \frac{1}{1-f+f/x} \xrightarrow{x \to \infty} \frac{1}{1-f}$$

Beispiel Amdahls Gesetz

- Angenommen ein Programm läuft in 100 Sekunden, wobei Multiplikationen 80 Sekunden davon verbrauchen.
  - Um wieviel muss die Geschwindigkeit der Multiplikation erhöht werden, wenn das Programm 4-mal schneller laufen soll?

$$S = \frac{1}{1 - f + f / x} \Rightarrow 4 = \frac{1}{0.2 + 0.8 / x} \Rightarrow 0.05 = 0.8 / x \Rightarrow x = 16$$

- Wie wird es 5-mal schneller? $x \to \infty$

- Erneut das 3. Design Prinzip:
  - **Optimiere den häufig vorkommenden Fall**

Weitere Beispiele

- Angenommen wir verbessern einen Prozessor, sodass alle Gleitkomma-Befehle fünfmal schneller laufen. Wenn die Ausführungszeit vom Benchmark vor der Gleitkomma-Verbesserung 10 Sekunden ist, wie wird der *Speedup* sein, wenn nun 5 Sekunden für Gleitkomma-Befehlen verwendet werden?

- Wir suchen einen Benchmark für die neue Gleitkomma-Einheit und wollen, dass dieser über das gesamte Programm einen *Speedup* von 3 anzeigt. Ein Benchmark den wir erwägen läuft mit der alten Gleitkomma-Hardware 100 Sekunden lang. Wie hoch muss der Anteil der Gleitkomma-Befehle an der gesamten Ausführungszeit sein, um bei diesem Benchmark den gewünschten *Speedup* hervorzurufen?

MIPS und MFLOPS

- MIPS (Million Instructions per Second)

$$\text{MIPS} = \frac{\text{Anzahl von Instruktionen}}{\text{Ausführungszeit in Sekunden} \times 10^6}$$

- Probleme bei der Verwendung von MIPS als Maß:
  - Leistungsfähigkeit der Befehle wird nicht berücksichtigt
    - Prozessoren mit unterschiedlichen Befehlssätzen können nicht verglichen werden.
  - MIPS variiert für verschiedene Programme
    - Es gibt keinen einzelnen MIPS-Wert für alle Programme
  - MIPS kann invers zur Leistung variieren
    - Programm mit 1M Befehlen und CPI 1,0 hat höheren MIPS-Wert als Programm für das selbe Problem mit 0,4M Befehlen und CPI 2.0

- MFLOPS (*mega* (10^6) *floating point operations per second*) ähnlich

Zusammenfassung

- Ausführungszeit ist das einzig gültige Rechenleistungsmaß
- CPU-Leistungsgleichung: $T = N_{instr} \times CPI \times t_{cycle}$
- Wenn Programme nicht gleichhäufig ausgeführt werdem:
  - Gewichtetes arithmetisches Mittel
  - Auf Referenzmaschine normalisieren und geometrisches Mittel bilden (nicht arithmetischen Durchschnitt verwenden!)
- SPEC (Standard Performance Evaluation Corporation)
  - Satz von realen Programmen und Eingaben zum Leistungsvergleich
  - www.spec.org
- Amdahls Gesetz: $S = \frac{1}{1 - f + f / x}$